Universität
Augsburg
University

Bachelorarbeit

Efficient convolutional neural network with extremely limited resources for the classification of large-scale image sets

TEMKENG Thibaut

Datum der Abgabe: Ende Oktober

Betreuung: Name der Betreuer/ des Betreuers:Shou Liu

Fakultät für Embedded Intelligence for Health Care and Wellbeing

Erklärung

Ich versichere wahrheitsgemäß, die Arbeit selbstständig verfasst, alle benutzten Hilfsmittel vollständig und genau angegeben und alles kenntlich gemacht zu haben, was aus Arbeiten anderer unverändert oder mit Abänderungen entnommen wurde, sowie die Satzung der Universität Augsburg zur Sicherung guter wissenschaftlicher Praxis in der jeweils gültigen Fassung beachtet zu haben.

Ort, den Datum

Inhaltsverzeichnis

PooL	Pooling Layer
NN	neuronales Netz
ML	Maschine Lernen
ConvL	Convolutional Layer
KI	Künstliche Intelligenz
DNN	Tiefe neuronale Netze
FCL	Fully Connected Layer
CNN	Convolutional Neural Network
DSC	Depthwise Separable Convolution
KNN	Künstliches neuronales Netzwerk
ILSVRC	Large Scale Visual Recognition Challenge

1 Einleitung

In den letzten Jahren haben CNNs die besten Ergebnisse bei der Lösung verschiedener Aufgaben im Bereich der Computer Vision erzielt und viele andere Bereiche von Grund auf revolutioniert.Getrieben durch die Zunahme der Datenmenge und große Fortschritte in der Rechenleistung hat sich ein neuer Trend zur Entwicklung von größeren, tieferen und komplizierteren CNNs herausgebildet. Aber dieser Trend bringt nicht nur eine immer bessere Genauigkeit, sondern auch viele neue und zentrale Probleme oder Herausforderungen mit sich.

Erstens verwenden die CNNs mit guten Ergebnissen meist mehrere Millionen Parameter, was ebenfalls zu viel Speicherplatz erfordert.Aber die verfügbaren internen Speicher für die Geräte wie Smart-Kameras, Mobiltelefone usw., in denen die CNN eingesetzt sind oder werden sollen, sind sehr beschränkt,was die Nutzung von CNN in bestimmten Anwendungen bisher unmöglich macht.Zweitens sind in einem CNN etwa eine oder mehrere Milliarden Rechenoperationen und Speicherzugriffe erforderlich, die alle Strom verbrauchen und Wärme abgeben, die die begrenzte Batteriekapazität erschöpfen kann und/oder die thermischen Grenzen des Geräts testen, um eine einzige Vorhersage zu treffen[1], daher ist die Durchführung von Inferenz auf stromsparenden System-on-a-Chip (SoCs) aufgrund der begrenzten verfügbaren Speicher- und Rechenressourcen eine große Herausforderung.

Unter Berücksichtigung dieser Herausforderungen ist eine wachsende Zahl von Arbeiten entstanden, die sich zum Ziel nehmen, Methoden zur Komprimierung von CNNs zu finden und gleichzeitig den möglichen Verlust an Modellqualität zu begrenzen. Der Entwurf neuer Architekturen mit effizienteren Operationen, wie z.B. die tiefenweise trennbare Faltung (*Depthwise Separable Convolution*), die die Standardfaltung in punktweise und tiefenweise Faltung (*Point/depth-wise convolution*) faktorisieren, ermöglicht die Reduzierung der Größe der Modelle im Vergleich zu bestehenden überparametrisierten Architekturen mit der Standardfaltung. Das CNN-Beschneiden von redundanten und nicht informativen Gewichten im Netzwerk ermöglicht eine signifikante Reduzierung der Netzwerkgröße in Abhängigkeit von den Anfangseinstellungen. Die CNN-Quantisierung, die darin besteht, den Bereich der Parameterwerte zu reduzieren, wodurch der Speicherbedarf verringert und die Inferenzzeit verbessert wird.

1.1 Motivation

In den letzten Jahren haben CNNs die besten Ergebnisse bei der Lösung verschiedener Aufgaben im Bereich der Computer Vision erzielt und viele andere Bereiche von Grund auf revolutioniert.Getrieben durch die Zunahme der Datenmenge und große Fortschritte in der Rechenleistung hat sich ein neuer Trend zur Entwicklung von größeren, tieferen und komplizierteren CNNs herausgebildet. Aber dieser Trend bringt nicht nur eine immer bessere Genauigkeit, sondern auch viele neue und zentrale Probleme oder Herausforderungen mit sich. Erstens verwenden die CNNs mit guten Ergebnissen meist mehrere Millionen Parameter, was ebenfalls zu viel Speicherplatz erfordert.Aber die verfügbaren internen Speicher für die Geräte wie Smart-Kameras, Mobiltelefone usw., in

denen die CNN eingesetzt sind oder werden sollen, sind sehr beschränkt,was die Nutzung von CNN in bestimmten Anwendungen bisher unmöglich macht.Zweitens sind in einem CNN etwa eine oder mehrere Milliarden Rechenoperationen und Speicherzugriffe erforderlich, die alle Strom verbrauchen und Wärme abgeben, die die begrenzte Batteriekapazität erschöpfen kann und/oder die thermischen Grenzen des Geräts testen, um eine einzige Vorhersage zu treffen[1], daher ist die Durchführung von Inferenz auf stromsparenden System-on-a-Chip (SoCs) aufgrund der begrenzten verfügbaren Speicher- und Rechenressourcen eine große Herausforderung.

1.2 Ziel der Arbeit.

Das Vorhaben dieser Arbeit ist es, mit Hilfe eines Convolutional Neural Network (CNN) ein Netzwerk zu entwickeln, das möglichst wenige Parameter zur Klassifizierung der großen Bildmengen verwendet und das bei der Lösung dieser Aufgabe mit den Standard CNNs wie *MobileNet* und *Xception*, die dabei die Ergebnisse, die auf den Stand der Technik sind, erreichen, mithalten oder ihnen Übertreffen kann. Dazu schlagen wir eine neue CNN-Architektur vor, die eine effiziente Nutzung der Parameter und eine bessere Inferenz ermöglicht. Darüber hinaus werden verschiedene Methoden und Hyperparameter untersucht, die im Stande sind, zum einen die Netzwerkleistung und die Inferenzzeit zu verbessern und zum anderen die Größe unseres CNN nochmals zu reduzieren.

1.3 Aufbau der Arbeit.

1. CNN mit zu wenig Speicherplatz.
    - geeignete Architektur.
2. CNN komprimieren.
    - Pruning.
    - Quantisierung.

-

2 Grundlagen

Im folgenden Kapitel werden die Grundlagen von neuronalen Netzwerken beschrieben, beginnend mit künstlichen neuronalen Netzen, gefolgt von einem Abschnitt über Faltungsneuronale Netzwerke und zum Abschluss ein Abschnitt über die verwendeten Datensätze und Bibliotheken.

2.1 Künstliche neuronale Netzwerke

2.1.1 Künstliches Neuron

Ein künstliches Neuron[19] ist eine mathematische Funktion, die das Verhalten vom biologischen Neuron nachbildet. Künstliche Neuronen sind elementare Einheiten jedes Künstliches neuronales Netzwerk (KNN). Das künstliche Neuron empfängt einen oder mehrere Inputs und bildet sie auf einen Output ab. Normalerweise wird jeder Eingabe x_i separat mit einem Gewicht w_i multipliziert und danach aufsummiert und zum Schluss wird die Summe durch eine Funktion geleitet, die als Aktivierungs- oder Übertragungsfunktion bekannt ist.Eine schematische Darstellung eines künstlichen Neurons ist in Abbildung 1 zu sehen.

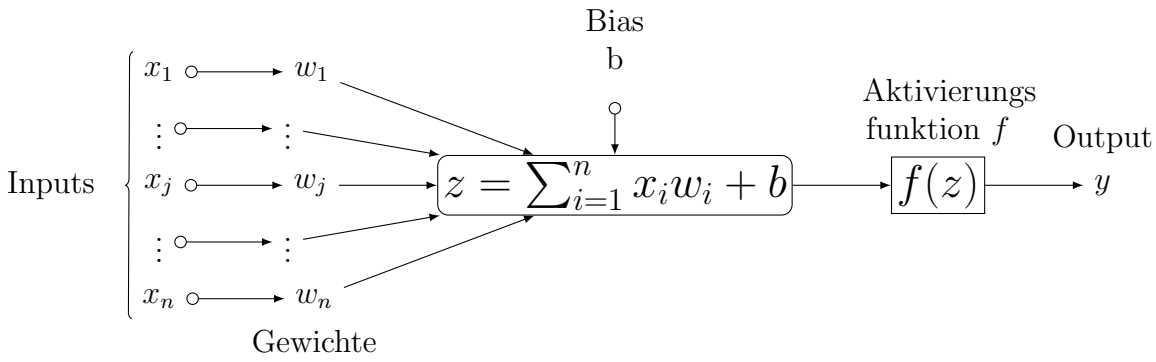

Abbildung 1: Funktionsweise eines künstlichen Neurons

Künstliche Neurone können aufgestapelt werden, um eine Schicht(*Layer*) zu bilden.Ein KNN besteht aus einer oder mehreren Schichten und je nach seiner Position in einem neuronales Netz (NN) wird eine Schicht anders genannt: Eingangsschicht(*Input Layer*) bzw. Ausgabeschicht(*Output Layer*), wenn das Layer die Eingangsdaten bzw. Ausgabedaten des neuronalen Netzes darstellt und versteckte Schicht(*Hidden Layer*), wenn es keine Eingang- oder Ausgabeschicht ist.Ein kurzer Überblick über die Darstellung von KNNs kann sich in Abbildung 18 verschafft werden.

2.1.2 Merkmalskarten(Feature-Maps)

Die Ausgabe einer Schicht wird als Aktivierungskarten oder Feature-Map(s) bezeichnet. Die Anzahl von Feature-Maps in einer Schicht ist gleich die Anzahl der Ausgabekanäle(*output channels*) bzw: Tiefe(*depth*) dieser Schicht. In einer Faltungsschicht ist ein

Feature-Map immer zweidimensional, während die Dimension eines Feature-Maps in einem Fully Connected Layer (FCL) nur von der des Inputs abhängt, genauer gesagt,für ein n-dimensionales Inputs ist ein Feature-Map $(n-1)$dimensional. Wie die Feature-Maps berechnet werden, hängt sehr vom Schichttyp ab. Es wird beispielsweise in einer Faltungsschicht die Faltungsoperation mehrmals auf die Eingabe angewendet und jedes Mal wird ein neues Feature-Map erhalten.

2.1.3 Filters

Ein Filter ist eine kleine Matrix, die die Extraktion von Features ermöglicht. Die modernen Architekturen von CNN verwendet immer mehr Filter (mindestens 2000), um bessere Ergebnisse zu erzielen. Wegen der zufällige Initialisierung von Filtern und ihrer großen Anzahl im CNN kann es vorkommen, dass mehrere Filter das gleiche Feature extrahieren, solche Filter werden als Redundant bezeichnet, oder dass Filter genau das Gegenteil von dem filtern, was wir wollen, nämlich unwichtige Informationen, deshalb werden während des Trainings die Filterparameter ständig geändert. Zwei nichtlineare Filter, d. h. Filter, die nicht proportional zueinander sind, lernen unterschiedliche Dinge.Man kann also daraus schließen, dass je größer die Anzahl an Filter ist, desto mehr Features gefiltert werden können oder besser sind die Ergebnisse, aber das ist in Allgemein falsch, da die guten Ergebnisse sehr stark davon abhängen, wie die Filter im CNN aufgestapelt sind. Zu viele Filtern in einem CNN können dazu führen, dass das CNN sowohl gute Features als auch schlechte schneller lernt und zu wenige Filter schränken die Kapazität des CNN ein, wichtige Features zu extrahieren, denn irgendwann wird es vorkommen, dass jedes Filter etwas Wichtiges gelernt hat, aber noch mehr Informationen werden benötigt, um die Trainingsdaten zu erklären. Es ist also wichtig die richtige Anzahl von Filtern zu finden.

-

2.1.4 Entwicklung von Künstlichen Neuronalen Netzen

2.2 Convolutional Neural Network

Dieser Absatz wird in zwei Teile aufgeteilt.Der erste Teil(*Feedforward*) beschreibt, wie sich die Daten durch das CNN bewegen und der zweite Teil(*Backforward*) beschreibt, wie die Parameter des CNN eingestellt werden.

2.2.1 Feedforward

2.2.1.1 Input Layer

Die Eingangsschicht stellt die Eingangsdaten dar. Hier müssen die Eingangsdaten dreidimensional sein.Also die Eingangsdaten von CNN haben immer die folgende Form $W \times H \times D$ wobei (W, H) der räumlichen Dimension und D die Tiefe der Daten entspricht. Z.B $100 \times 100 \times 3$ für ein RGB-Bild und $224 \times 224 \times 1$ für ein Graustufenbild.

2.2.1.2 Faltungsschicht

Die wichtigste Sicht bzw. der Hauptschicht in einem CNN ist die Faltungsschicht(Convolutional Layer (ConvL)). In jedem Fall bestehen die Eingabedaten eines CNN aus wichtigen und unwichtigen Informationen zur Lösung unseres Problems.Als wichtige und unwichtige Informationen haben wir z.B die starke Präsenz der weißen Farbe in einer Muschelsuppe bzw. die Präsenz eines Menschen, wenn man verschieden Ernährungsklasse klassifizieren möchte. Während des Trainings eines CNN wird versucht, diese relevanten Informationen aus den Daten zu entnehmen und die irrelevanten auszuschließen. Alles was ein CNN aus den Eingabedaten nutzt, um die Daten zu bestimmter Klassen zuzuordnen, wird als Feature bezeichnet. Das einzige bzw. das Hauptziel einer Faltungsschicht besteht darin, diese Features aus den Eingabedaten herauszuziehen. Dass eine Faltungsschicht in der Lage ist, Features selbst zu extrahieren, ohne dass man sie hinweist, was wichtig ist und was nicht, ist wirklich beeindruckend,Aber die Art und Weise, wie sie es tut, ist noch beeindruckender.

In einem ConvL wird die sogenannte Faltungsoperation(*convolution operation*) durchgeführt,dabei wird das komponentenweises Produkt(*Hadamard-Product*) zwischen einem kleinen Bereich der Eingabedaten und einem Kernel durchgeführt und dann die ganze aufsummiert. Eine Illustration der Faltungsoperation ist in der Abbildung 4a zu sehen. Die Resultante der Faltungsoperation wird die Aktivierung des Neurons genannt.Sollte diese Aktivierung des Neurons null sein, dann wird gesagt, dass das Neuron "*nicht aktiv*" ist und sonst ist es *aktiv*.Die null Aktivierung bedeutet, dass die vom Filter gesuchten Features nicht gefunden wurden. Je stärker oder wichtiger die Aktivierung eines Neurons ist, desto höher ist die Wahrscheinlichkeit, dass die vom Filter gesuchten Merkmale gefunden werden.(siehe Abbildung 4b). Um diese Faltungsoperation durchzuführen, müssen einige Hyperparameter vordefiniert sein, und zwar:

Die Anzahl und Größe von Filtern. Die Anzahl von Filtern gibt nicht nur an, wie viele Filter in dem ConvL verwendet werden, sondern auch ,wie oft die Faltungsoperation auf die Eingabe der Schicht durchgeführt wird, d.h die Anzahl der Feature-Maps oder die Tiefe der Schicht. Anstatt das ganze Bild zu betrachten, wenn man auf der Suche nach Features ist, was mit der Tatsache gleichbedeutend ist, dass jedes Neuron der Schicht mit allen Neuronen der vorherigen verbunden ist, wird nur einen lokalen Bereich des Bildes betrachtet, wir verbinden also jedes Neuron nur mit einem lokalen Bereich der Bild. Dieser lokaler Bereich wird als Empfangsfeld(*receptive field*) des Neurons bezeichnet und entspricht der Filtergröße.Es ist zu beachten, dass die Filtergröße nur der räumlichen Dimension des Filters entspricht. Die Tiefe des Filters ist gleich die vom Input, also für ein $(100, 100, 3)$ Bild haben alle Filter die Tiefe 3. Die Verwendung von solchen kleinen Filtern ist die Hauptidee hinter einer Faltungschicht. Filter haben im Allgemein eine kleine räumliche Dimension wie z.B 2×2, 3×3 oder 5×5, sonst verliert man einen großen Vorteil von ConvL, der darin besteht, die Speicheranforderung deutlich zu reduzieren, indem es die Gewichte verteilt.

Die Schrittgröße (*Stride*).

Abbildung 2: Einfluss der Schrittgröße auf die Größe der Feature-Maps

(a) *Schrittgröße=(1,1)* (b) *Schrittgröße=(2,2)*

Da ein Filter nur einen kleinen Bereich des Bilds wahrnehmen kann,wird eine Schrittgröße verwendet, um die Bewegung des Filters auf dem Bild zu steuern.Das Filter wird über das Bild von links nach rechts, von oben nach unten bewegt. Sei $S := (n, m)$ die Schrittgröße, dann wird das Filter von n Pixeln nach rechts für jede horizontale Bewegung des Filters und m Pixeln nach unten für jede vertikale Bewegung des Filters bewegt(siehe Abbildung 3a und 3b).Wie die folgende Tabelle zeigt,hängt die räumliche Dimension des Outputs sehr von der Schrittgröße ab.

Imagegröße	***Stride***	***Filtergröße***	***Output (räumliche Dim.)***	***Mit Padding***
$(100, 100, 3)$	$(1, 1)$	$(1, 1)$	$(100, 100)$	$(100, 100)$
$(100, 100, 3)$	$(1, 1)$	$(3, 3)$	$(98, 98)$	$(100, 100)$
$(100, 100, 3)$	$(2, 2)$	$(3, 3)$	$(49, 49)$	$(50, 50)$
$(100, 100, 3)$	$(1, 1)$	$(4, 4)$	$(97, 97)$	$(100, 100)$
$(100, 100, 3)$	$(1, 1)$	$(10, 10)$	$(91, 91)$	$(100, 100)$

Tabelle 1: Auswirkung von Schrittgröße,Filtergröße und Padding auf Output eines $(100, 100, 3)$ Bild.

Padding. Mit einem großen Filter lernt man in der Regel "mehr"als mit einem kleinen.Aber wie es in der Tabelle 1 zu sehen ist, hat man eine Reduktion der Dimension, wenn ein Filter mit Filtergröße > 1 angewendet wird und um die Dimension zu behalten, wird vor der Anwendung der Filter auf das Bild eine Füllung(*padding*) an den Rändern des Bilds gemacht. Diese Füllung ermöglicht erstens den Entwurf immer tiefer Netzwerke, denn es gibt nach jedem ConvL einen kleinen Dimensionverlust und zweitens,dass die Information an Rändern nicht zu schnell verschwunden werden.Um die Ränder einer Eingabe zu füllen, werden sehr oft Nullen (*zero padding*) verwendet, oder die Pixel, die an der Grenze liegen, werden wiederholt.

In einem CNN mit mehreren ConvLs beschäftigen sich die ersten ConvLs mit dem Erlernen einfacher Merkmale wie Winkel, Kanten oder Linien und je tiefer das CNN ist, desto komplexer sind die extrahierten Merkmale. Das liegt daran, dass jede nachfolgende Schicht einen größeren Bereich des Originalbildes betrachten oder „sehen " kann.Nehmen wir an,dass die zwei ersten Layers eines CNNs Filter von Größe 3×3 und ein *Stride*

= (1, 1) verwenden.Die erste Schicht betrachte immer 3×3 benachbarte Pixel des Originalbildes und speichert seine Aktivierung auf einem Pixel. Jetzt wenn die zweite ConvL 3×3 benachbarte Pixel betrachtet, betrachtet sie eigentlich 5×5 benachbarte Pixel des Originalbildes.Wir können uns deshalb vorstellen, dass irgendwo in späteren Schichten Filter das gesamte Originalbild betrachten.

(a) Matrixdarstellung

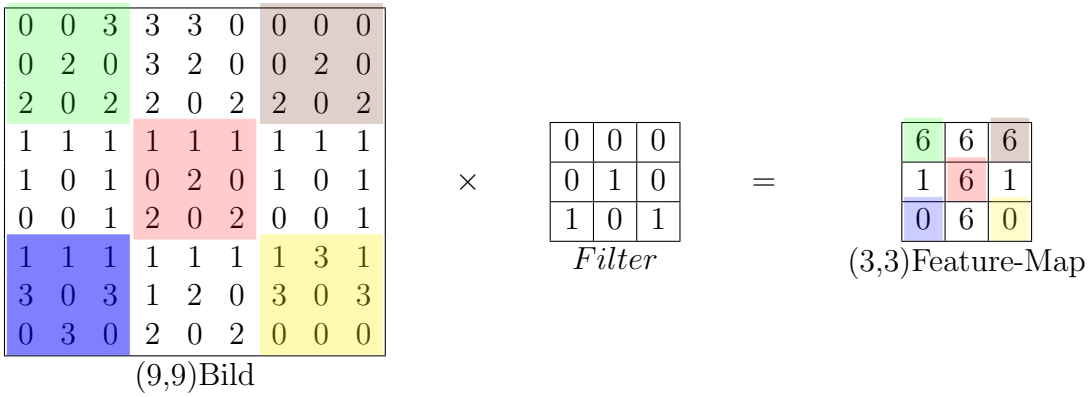

(b) Pixeldarstellung

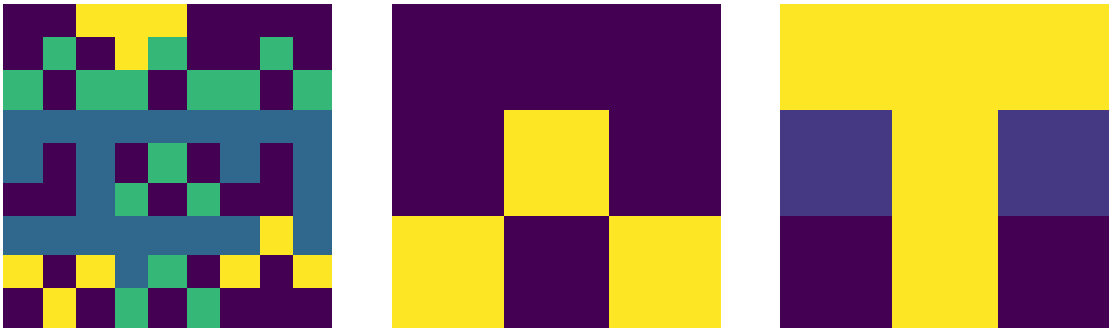

Abbildung 4: Faltungsoperation mit einem 3×3-Filter und Schrittgröße = 3

2.2.1.3 Aktivierungsfunktion

Das neuronale Netzwerk wird während des Trainings mit vielen Daten gespeist und das sollte in der Lage sein, aus diesen Daten zwischen relevanten und irrelevanten Informationen Unterschied zu machen. Die Aktivierungsfunktion auch Transferfunktion oder Aktivitätsfunktion genannt, hilf dem NN bei der Durchführung dieser Trennung. Es gibt sehr viele Aktivierungsfunktionen und in folgenden werden wir sehen, dass eine

Aktivierungsfunktion je nach zu lösende Aufgaben vorzuziehen ist.

$$\begin{cases} Y = f(\Sigma(Gewicht * Input + Bias)) \\ f := Aktivierungsfunktion \end{cases}$$

Binäre Treppenfunktion ist extrem einfach, siehe Abbildung 5, definiert als $f(x) = \begin{cases} 1, & \text{if } x \geq a \text{ (a:= Schwellenwert)} \\ 0, & sonst \end{cases}$. Sie ist für binäre Probleme geeignet, also Probleme wo man mit *ja* oder *nein* antworten sollte.Sie kann leider nicht mehr angewendet werden, wenn es mehr als zwei Klassen klassifiziert werden soll oder wenn das Optimierungsverfahren gradientenbasierend ist, denn Gradient immer null.

Abbildung 5: Binäre Treppenfunktion

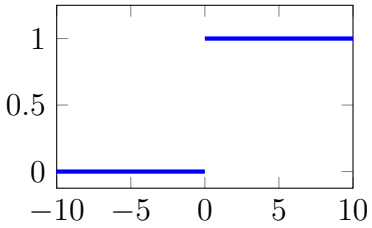

(a) Binäre Treppenfunktion

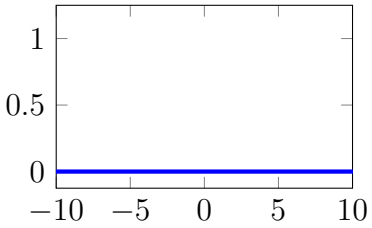

(b) Ableitung Binäre Treppenfunktion

Lineare Funktion ist definiert als $f(x) = ax$, $f'(x) = a$, siehe Abbildung 7. Sie ist monoton, null zentriert und differenzierbar. Es ist jetzt möglich,nicht nur binäre Probleme zu lösen und während der Backpropagation mit Hilfe von gradientenbasierenden Optimierungsverfahren Parameter anzupassen, denn der Gradient ist nicht mehr null, also sie ist besser als binäre Funktion. Aber die Anwendung der linearen Aktivierungsfunktion auf ein mehrschichtiges Netzwerk ist nicht von Vorteil,denn ein mehrschichtiges Netz mit linearer Aktivierungsfunktion kann auf ein einschichtiges Netz überführt werden und mit einem einschichtigen Netz können leider komplexe Probleme nicht gelöst werden.Außerdem ist der Gradient immer konstant. Der Netzfehler wird also nach einigen Epochen nicht mehr minimiert und das Netz wird immer das Gleiche vorhersagen.

Abbildung 7: Lineare Funktion

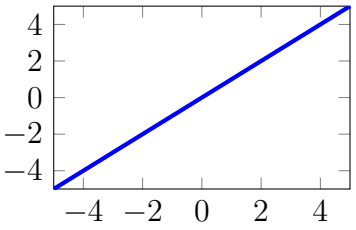

(a) Lineare Funktion: $f(x) = x$

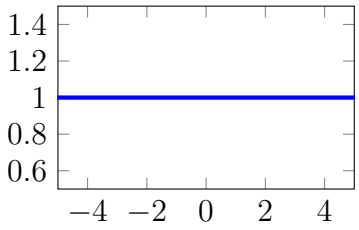

(b) Ableitung Lineare Funktion: $f'(x) = 1$

Logistische Funktion ist definiert als $f(x) = \frac{1}{1+exp(-x)}$,$f'(x) = \frac{exp(x)}{(1+exp(x))^2}$, siehe Abbildung 9. Sie ist differenzierbar, monoton, nicht linear und nicht null zentriert(hier nur positive Werte).Zwischen $[-3, +3]$ ist der Gradient sehr hoch.Kleine Änderung in der Netzinput führt also zu einer großen Änderung der Netzausgabe. Diese Eigenschaft ist bei Klassifikationsproblemen sehr erwünscht.Die Ableitung ist glatt und von Netzinput abhängig. Parameter werden während der Backpropagation je nach Netzinput angepasst. Außerhalb von $[-3, 3]$ ist der Gradient fast gleich null, daher ist dort eine Verbesserung der Netzleistung fast nicht mehr möglich.Dieses Problem wird Verschwinden des Gradienten *(vanishing gradient problem)* genannt.Außerdem konvergiert das Optimierungsverfahre sehr langsam und ist wegen wegen der exponentiellen (e^x) Berechnung rechenintensiv.

Abbildung 9: Logistische Aktivierungsfunktion:$sigmoid(x)$.

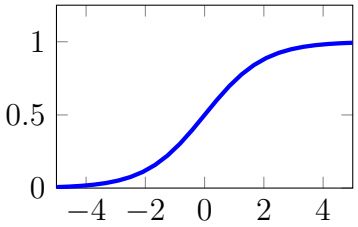

(a) Logistische Aktivierungsfunktion.

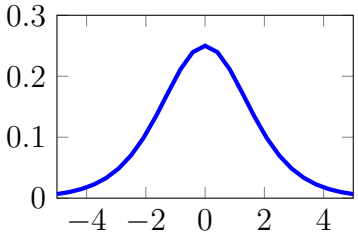

(b) Ableitung der Logistische Funktion.

Tangens Hyperbolicus ist definiert als $tanh := 2sigmoid(x) - 1$, siehe Abbildung 11.Außer dass sie null zentriert ist, hat sie die gleichen Vor- und Nachteile wie die Sigmoid Funktion.

Abbildung 11: Tangens Hyperbolicus.

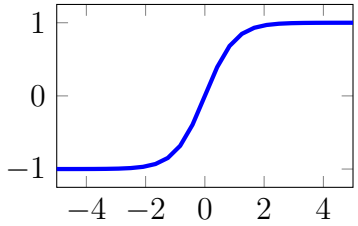

(a) Tangens Hyperbolicus.

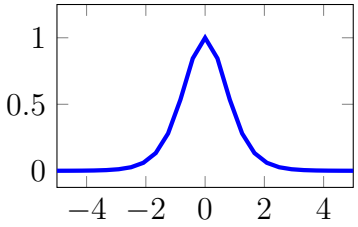

(b) Ableitung der Tangens Hyperbolicus.

Rectified Linear Unit (ReLU) ist definiert als $f(x) = max(x, 0)$, siehe Abbildung 13. Sie ist sehr leicht zu berechnen. Es gibt keine Sättigung wie bei *Sigmoid* und *tanh*. Sie ist nicht linear,deshalb kann den Fehler schneller propagiert werden.Ein größter Vorteil der ReLU-Funktion ist, dass nicht alle Neurone gleichzeitig aktiviert sind, negative Eingangwerte werden zu null,daher hat die Ausgabe von Neuronen mit negativen Eingangwerten

keine Einfluss auf die Schichtausgabe, diese Neurone sind einfach nicht aktiv.Das Netz wird also spärlich und effizienter und wir haben eine Verbesserung der Rechenleistung. Es gibt keine Parameteranpassungen, wenn die Eingangwerte negative sind, denn der Gradient ist dort null.Je nachdem wie die Bias initialisiert sind, werden mehrere Neuron töten,also nie aktiviert und ReLU ist leider nicht null zentriert.

Abbildung 13: ReLU Aktivierungsfunktion

(a) ReLU Aktivierungsfunktion

(b) Ableitung der ReLU Funktion

Leaky ReLU Funktion ist definiert als $f(x) = \begin{cases} x, & \text{if } x > 0 \\ 0.01x, & sonst \end{cases}$, siehe Abbildung 15. Sie funktioniert genauso wie die ReLU-Funktion, außer dass sie das Problem des toten Neurons löst und sie ist null zentriert.Es gibt somit immer eine Verbesserung der Netzleistung, solange das Netz trainiert wird.Wenn das Problem von Leaky ReLU nicht gut gelöst wird, wird empfohlen, die *Parametric ReLU* (PReLU) Aktivierungsfunktion zu verwenden, die während der Training selber lernt, Problem der toten Neuronen zu lösen.

Abbildung 15: Leaky ReLU Funktion

(a) Leaky ReLU Funktion

(b) Ableitung der Leaky ReLU Funktion

Softmax ist definiert als $f(x_1, x_2, \cdots, x_n) = \frac{(e^{x_1}, x_2, \cdots, e^{x_n})}{\sum_{i=1}^{n} e^{x_i}}$.Die Softmax-Funktion würde die Ausgänge für jede Klasse zwischen null und eins zusammendrücken und auch durch die Summe der Ausgänge teilen. Dies gibt im Wesentlichen die Wahrscheinlichkeit an, dass sich der Input in einer bestimmten Klasse befindet.

In allgemein wird die ReLU aufgrund des Problems der toten Neurone nur in versteckte Schichten und die Softmax-Funktion bei Klassifikationsproblemen und Sigmoid-Funktion bei Regressionsproblemen in Ausgabeschicht verwenden.

2.2.1.4 Pooling Layer

Die Funktionsweise von Pooling-Schichten ist sehr ähnlich zu der von ConvLs. Das Filter wird durch die Inputdaten bewegen und dabei anstatt die Faltungsoperation durchzuführen, werden die Inputdaten Blockweise zusammengefasst. Ein Pooling-Layer besitzt nur eine Schrittgröße und eine Filtergröße. Das Filter in PooL ist in Gegensatz zu Filtern in ConvL nicht lernbar ist, es gibt nur an, wie groß der Block, der zusammengefasst wird, sein muss. Als Standard werden ein 2×2 Filter und eine 2×2 Schrittgröße verwendet, was die Dimension der Inputdaten um mindestens die Hälfte reduziert. Interessanter ist, dass die wichtigen Informationen oder Muster auch nach der Pooling-Schicht verfügbar bleiben und wir somit sowohl eine Erhöhung der Rechengeschwindigkeit als auch eine Reduzierung der Netzwerkparameter haben.Noch dazu sind PooLs invariant gegenüber kleiner Veränderung wie Parallelverschiebung.

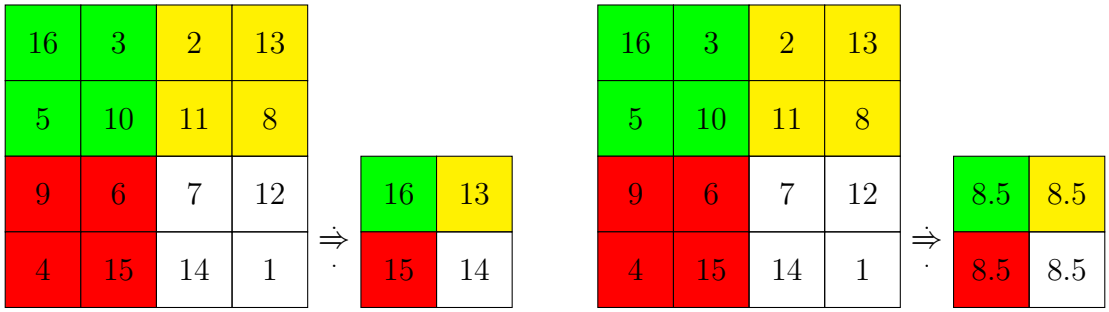

Abbildung 17: Funktionsweise der Pooling-Sicht mit Pooling_size= $(2, 2)$ und $Stride = 2$

Je nachdem, wie die Zusammenfassung der Blöcke in einem Pooling Layer (PooL) durchgeführt wird, haben die PooLs unterschiedliche Namen. Werden die Werte eines Blockes durch den Maximalwert des Blocks ersetzt, dann sprechen wir von Max-Pooling-Layer (siehe Abbildung 17 links), wenn sie durch den Mittelwert des Blocks ersetzt, wird von Average-Pooling-Layer (siehe Abbildung 17 rechts) und wenn die Filtergröße gleich die räumliche Dimension der Eingangdaten ist, sprechen wir von Global-Max-Pooling-Layer und Global-Average-Pooling-Layer, es wird also alle Neurone in einem Kanal zu einem Neuron. Die Ausgabedimension solcher Schicht entspricht der Anzahl der Kanäle bzw. Tiefe der Inputdaten.

Das Global-Pooling-Layer wird sehr oft angewendet, um das Vorhandensein von Merkmale in Daten aggressiv zusammenzufassen. Es wird auch manchmal in Modellen als Alternative zur Flatten-Schicht, die mehrdimensionale Daten zu eindimensionale umwandelt, beim Übergang von ConvLs zu einem FCL verwendet.

2.2.1.5 Multi-layer Perzeptron (Fully Connected Layer)

Nachdem die relevanten Merkmale durch die Wiederholung von Conv , Pooling-Schichten und anderen Schichten extrahiert worden sind, wenden sie in FCLs kombiniert, um die Netzwerkeingabe zu einer bestimmten Klasse zuzuordnen. Die FCLs des CNN ermöglichen, Informationssignale zwischen jeder Eingangsdimension und jeder Ausgangsklasse

zu mischen, so dass die Entscheidung auf dem gesamten Bild basieren kann. Die FCLs funktionieren eigentlich genau wie ConvLs, außer dass jedes Neuron in FCL mit allen Neuronen und nicht mit einem kleinen Bereich von Neuronen im vorherigen Layer verbunden ist.Ein NN mit nur FCLs sieht wie in Abbildung18 aus.

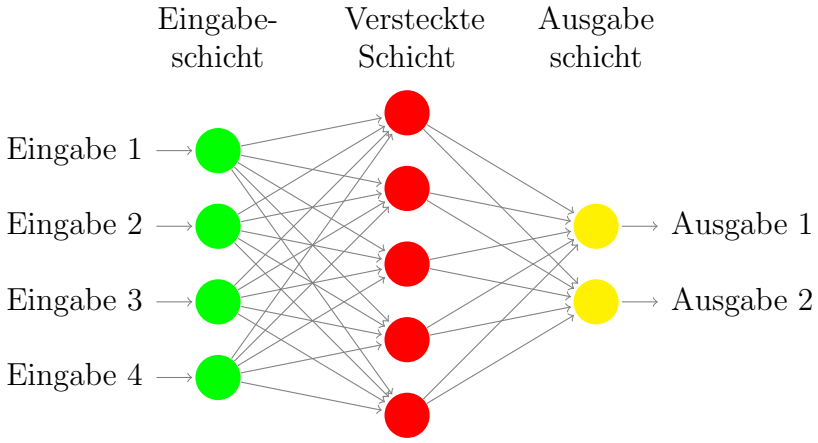

Abbildung 18: Darstellung eines neuronalen Netzes

Aufgrund der hohen Anzahl von Verbindungen zwischen Neuronen in einem FCL wird viel Speicher benötigt und verlangsamt auch das Training, es ist auch einer der Gründe, weshalb die FCLs meist nur in der letzten Schicht von CNN zur Klassifizierung verwendet werden und die Anzahl der Neuronen in letzter Schicht entspricht der Anzahl von Klassen.

2.2.2 Backforward

2.2.2.1 Fehlerfunktion

Das Training von CNNs besteht darin, den vom CNN begangenen Fehler zu korrigieren bzw. zu minimieren, daher wird es sehr oft als ein Optimierungsverfahren betrachtet. Wie gut die Vorhersage des neuronalen Netzes gerade ist, wird durch eine Fehlerfunktion auch Kostenfunktion genannt quantifiziert oder angegeben. Die Fehlerfunktion bringt die Ausgabewerte des NNs mit den gewünschten Werten in Zusammenhang. Sie ist ein nichtnegativer Wert und je kleiner dieser Wert wird, desto besser ist die Übereinstimmung des CNNs.Es wird in Laufe des Trainings von CNNs versucht, diese Kostenfunktion mit Gradient basierten Verfahren zu minimieren(siehe Absatz 2.2.2.4)

Die meisten benutzten Kostenfunktionen sind die Kreuzentropie (*cross-entropy*, Gleichung 2.2)(CE) und die mittlere quadratische Fehler (*mean squared error*,Gleichung 2.1)(MSE).

$$MSE(Y, \widehat{Y}) = \frac{1}{n} \sum_{i=1}^{n} (Y_i - \widehat{Y}_i)^2 \tag{2.1}$$

$$CE(Y, \widehat{Y}) = -\frac{1}{n} \sum_{i=1}^{n} Y_i \log(\widehat{Y}_i) \tag{2.2}$$

Y :Satz von echten Labels n :Die Batchgröße $\widehat{Y}$:Vorhersagesatz

Im Gegenteil zu CE Fehlerfunktionen,die sich nur auf Wahrscheinlichkeitsverteilungen anwenden lassen, können die MSE auf beliebige Werte angewendet werden. Nach [11, Pavel et al] ermöglicht die CE-Verlustfunktion ein besseres Finden lokaler Optima als die MSE-Verlustfunktion und das soll daran liegen, dass das Training des MSE Systems schneller in einem schlechten lokalen Optimum stecken bleibt, in dem der Gradient fast null ist und damit keine weitere Reduzierung der Netzfehler ermöglicht.Im Allgemein ist die CE Kostenfunktion für die Klassifikationsprobleme und die MSE Fehlerfunktion für die lineare Regression-Probleme besser.

2.2.2.2 Gradient

Der Gradient einer Funktion ist die erste Ableitung einer Funktion und in mehrdimensionalem Raum ist der Gradient einer Funktion der Vektor, dessen Einträge die ersten partiellen Ableitungen der Funktion sind. Der Gradient an einem Punkt gibt die Richtung der steilsten Anstieg der Funktion an diesem Punkt. Also da wir die Kostenfunktion minimieren möchten, sollen wir lieber immer in die Gegenrichtung des Gradienten gehen.In auf dem Gradient basierten Optimierungsverfahren wird der Gradient benutzt, um die lokalen oder globalen Extremwerte(hier das Minimum) zu erreichen. Da wir jetzt die Richtung des Minimums herausgefunden haben, bleibt noch zu bestimmen ,wie wir in diese Richtung gehen sollen.

2.2.2.3 Lernrate

Die Lernrate oder Schrittweite beim maschinellen Lernen ist ein Hyperparameter, der bestimmt, inwieweit neue gewonnene Informationen alte Informationen überschreiben sollen[14], in anderen Worten wie schnell wir ans Ziel Kommen. Je nachdem, wie die Lernrate gesetzt wird, werden bestimmte Verhalten beobachtet (Siehe Absatz 4.4) und sie nimmt sehr oft Werte zwischen 0.00001 und 0.5: Die Lernrate muss allerdings im Intervall $]0, 1[$ Werte annehmen, sonst ist das Verhalten des NN nicht vorhersehbar bzw. konvergiert das Verfahren einfach nicht. Für jeden Punkt x aus dem Parameterraum gibt es eine optimale Lernrate $\eta_{opt}(x)$, sodass ein globales oder lokales Minimum sofort nach der Parameteranpassung erreicht wird. Da $\eta_{opt}(x)$ am Trainingsanfang leider nicht bekannt ist, wird die Lernrate in die Praxis vom Programmierer basiert auf seine Kenntnisse mit NNs oder einfach zufällig gesetzt.

2.2.2.4 Gradientenabstiegsverfahren

Aktuelle leistungsfähige DNN bestehen fast immer aus Million Variable (lernbarer Parameter). Wir können uns ein DNN als eine Gleichung mit Millionen von Variablen vorstellen, die wir lösen möchten. Mit Hilfe der Daten wollen wir uns in einem Raum, dessen Dimension größer als eine Million ist, bewegen, um die optimalen Parameter(Parameter, die die Trainingsdaten korrekt abbilden) zu finden. Aufgrund der unendlichen Anzahl von Punkten im solchen Räume wäre es nicht sinnvoll,einen Punkt zufällig auszuwählen, dann überprüfen, ob er optimal ist und, wenn nicht, nochmals einen anderen Punkt zufällig auszuwählen. Genauer zu diesem Zeitpunkt kommen Gradientenabstiegsverfahren zum Einsatz. Die Gradientenabstiegsverfahren sind Verfahren, die auf dem Gradient basieren, um Optimierungsprobleme zu lösen.Hier wird Gradientenabstiegsverfahren verwendet, um sich der optimalen Parametern anzunähern oder sie zu finden.

Ablauf eines Gradientenverfahrens im DNN. Das Gradientenabstiegsverfahren kann in drei Hauptschritte aufgeteilt werden.Die Abbildung 19 stellt das Backpropagation-Verfahren bildlich dar.

Beim ersten Schritt wird ein zufälliger Punkt aus dem Parameterraum ausgewählt und davon ausgehend wird der Parameterraum exploriert. Dieser erste Schritt entspricht der Netzparameterinitialisierung am Trainingsanfang.

Der zweite Schritt besteht darin, die Abstiegsrichtung zu bestimmen.Dazu werden zuerst die Eingangdaten in das CNN eingespeist(*Forwardpropogation*), danach wird der Fehler zwischen den Netzvorhersagen und den korrekten Werten berechnet. Ein Fehler gibt es (fast) immer, denn die Initialisierung wird zufällig gemacht und die Wahrscheinlichkeit, dass wir von Anfang an die optimalen Werte finden, ist verschwindend klein und zuletzt wird der Gradient(2.2.2.2) der Kostenfunktion in abhängig von den gegebenen Eingangdaten und den erwarteten Werten berechnet.

Beim letzten Schritt wird die Schrittweite bestimmen.Die Lernrate (2.2.2.3) oder die Schrittweite wird vor Trainingsbeginn festgelegt oder während des Trainings abhängig von aktuellem Netzzustand allmählich adaptiert.

Variante des Gradientenverfahrens .

Bisher existiert drei Variante des Gradientenabstiegsverfahren, die sich nur durch die Größe der Daten, die sie verwendet, um den Gradienten der Kostenfunktion berechnet, unterscheidet.

1. **Stochastic Gradient Descent (SGD)**: Bei SGD wird jeweils ein Element bzw. Sample aus der Trainingsmenge durch das NN durchlaufen und den jeweiligen Gradienten berechnen, um die Netzwerkparameter zu aktualisieren.Diese Methode wird sehr oft online Training genannt,denn jedes Sample aktualisiert das Netzwerk. SGD verwendet geringer Speicherplatz und die Iterationen sind schnell durchführbar.Zusätzlich kann die Konvergenz für großen Datensatz wegen der ständigen Aktualisierung der Netzwerkparameter beschleunigt werden.Diese ständigen Aktualisierung hat die Schwankung der Schritte in Richtung der Minima zur Folge,

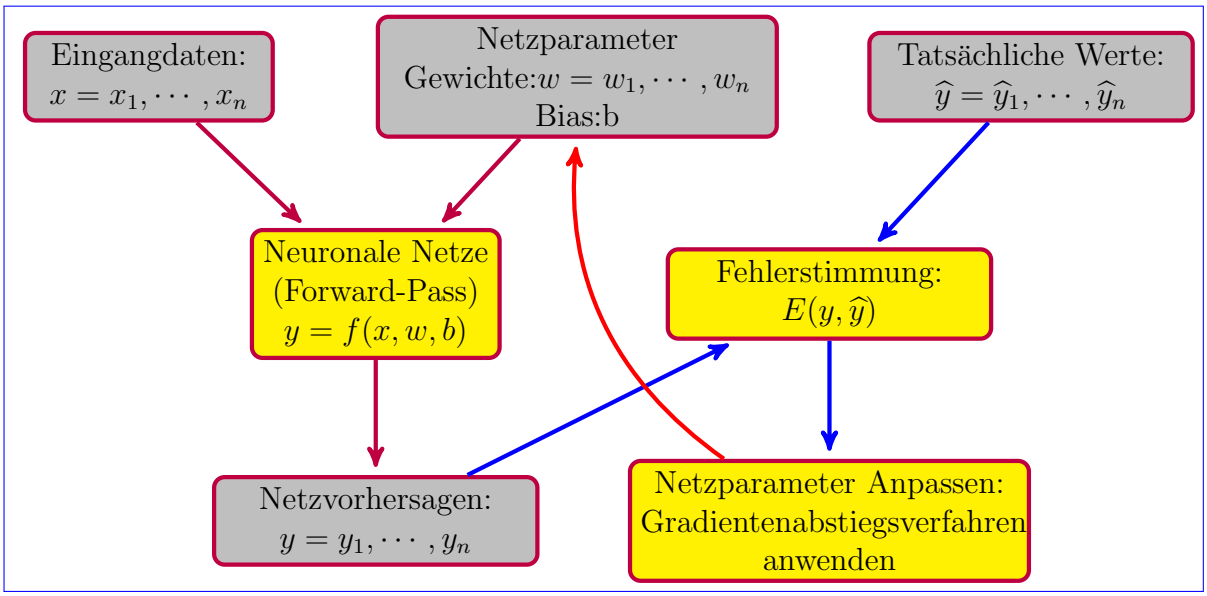

$f(x, w, b)$: Netzfunktion. $E(y, \widehat{y})$: Kostenfunktion.
η: Lernrate. $\longrightarrow$: Backward-Pass.
$\longrightarrow$: Forward-Pass $\longrightarrow$: Fehlerfunktion

Abbildung 19: Ablauf der Backpropagation

was die Anzahl der Iteration bis zum Erreichen des Minimums deutlich ansteigt und dabei helfen kann, aus einem unerwünschten lokalen Minimum zu entkommen.Ein großer Nachteil dieses Verfahren ist der Verlust der parallelen Ausführung, es kann jeweils nur ein Sample ins NN eingespeist werden. Der Algorithmus 1 zeigt den Ablauf von SGD.

Input: loss function E, learning rate η, dataset X, y und das Modell $F(\theta, x)$
Output: Optimum θ which minimizes E

while *converge* **do**
  Shuffle X, y
  for x_i, y_i *in* X, y **do**
    $\tilde{y} = F(\theta, x_i)$
    $\theta = \theta - \eta \cdot \frac{1}{N} \sum_{i=1}^{N} \frac{\partial E(y_i, \tilde{y}_i)}{\partial \theta}$
  end
end

Algorithm 1: Stochastic Gradient descent(SGD) [3].

2. **Batch Gradient Descent (BGD)**: BGD funktioniert genauso wie SGD, außer dass der ganze Datensatz statt jeweils ein Element aus dem Datensatz zur Netzwerkparameteraktualisierung genutzt wird.Jetzt kann das Verfahren einfach

parallel ausgeführt werden, was den Verarbeitungsprozess des Datensatzes stark beschleunigt. BGD weist im Vergleich zu SGD weniger Schwankungen in Richtung des Minimums der Kostenfunktion auf, was das Gradientenabstiegverfahren stabiler macht.Außerdem ist das BGD recheneffizienter als das SGD, denn nicht alle Ressourcen werden für die Verarbeitung eines Samples, sondern für den ganzen Datensatz verwendet.BGD ist leider sehr langsam,denn die Verarbeitung des ganzen Datensatz kann lange dauern und es ist nicht immer anwendbar, denn sehr große Datensätze lassen sich nicht im Speicher einspeichern.Der Algorithmus 2 zeigt den Ablauf von BGD.

Input: loss function E, learning rate η, dataset X, y und das Modell $F(\theta, x)$
Output: Optimum θ which minimizes ϵ

while *converge* **do**
  $\tilde{y} = F(\theta, x)$
  $\theta = \theta - \eta . \frac{1}{N} \sum_{i=1}^{N} \frac{\partial \epsilon(y, \tilde{y})}{\partial \theta}$
end

Algorithm 2: Batch Gradient descent [3].

3. **Mini-batch Stochastic Gradient Descent(MSGD):** MSGD ist eine Mischung aus SGD und BGD.Dabei wird der Datensatz in kleine Mengen (*Mini-Batch oder Batch*) möglicherweise gleicher Größe aufgeteilt.Je nachdem,wie man die Batch-Größe setzt, enthalten wir SGD oder BGD wieder. Das Training wird Batch-Weise durchgeführt, d.h. es wird jeweils ein Batch durch das NN propagiert, der Verlust jedes Sample im Batch wird berechnet und dann deren Durchschnitt benutzt, um die Netzwerkparameter zu anzupassen.MSGD verwendet den Speicherplatz effizienter und kann von Parallelen Ausführung profitieren. Noch dazu konvergiert MSGD schneller und ist stabiler. In die Praxis wird fast immer das MSGD Verfahren bevorzugt.Der Algorithmus 3 zeigt den Ablauf von MSGD

Input: loss function E, learning rate η, dataset X, y und das Modell $F(\theta, x)$
Output: Optimum θ which minimizes E

while *converge* **do**
  Shuffle X, y
  for *each batch of* x_i, y_i *in X, y* **do**
    $\tilde{y} = F(\theta, x_i)$
    $\theta = \theta - \eta . \frac{1}{N} \sum_{i=1}^{N} \frac{\partial E(y_i, \tilde{y_i})}{\partial \theta}$
  end
end

Algorithm 3: Mini-Batch Stochastic Gradient descent(MSGD) [3].

2.3 Datensätze und Bibliothek

2.3.1 Datensätze

1. **Food-101**[26]

   a) **Food-101-original** ist ein Datensatz von 101 Lebensmittelkategorien mit 101.000 Bilder. Für jede Klasse werden 250 manuell überprüfte Testbilder sowie 750 Trainingsbilder bereitgestellt. Die Trainingsbilder wurden bewusst nicht gereinigt und enthalten daher noch etwas Rauschen. Dies geschieht meist in Form von intensiven Farben und manchmal falschen Etiketten. Alle Bilder wurden so skaliert, dass sie eine maximale Seitenlänge von 512 Pixel aufweisen.

   b) **Food-101 von Tensorflow** Dieser Datensatz enthält die gleiche Anzahl von Bildern wie der soeben beschrieben, Aber der Datensatz wird nicht aufgeteilt und nicht gereinigt und enthalten daher noch etwas Rauschen. Dies geschieht meist in Form von intensiven Farben und manchmal falschen Etiketten.Für unsere Arbeit wurde jede Kategorie in drei(Trainings-, Auswertungs- und Testdatensatz) aufgeteilt ist, die 800, 100 bzw. 100 Bilder umfasst.

2. **Flowers-102** Der Datensatz *Oxford Flowers 102* ist ein konsistenter Datensatz von 102 Blumenkategorien, die in Großbritannien häufig vorkommen. Jede Klasse besteht aus 40 bis 258 Bildern. Die Bilder haben große Variationen in Maßstab, Pose und Licht. Darüber hinaus gibt es Kategorien, die innerhalb der Kategorie große Unterschiede aufweisen, und mehrere sehr ähnliche Kategorien. Der Datensatz ist unterteilt in einen Trainingssatz, einen Validierungssatz und einen Testsatz. Das Trainingsset und das Validierungssatz bestehen jeweils aus 10 Bildern pro Klasse (insgesamt je 1020 Bilder). Das Testset besteht aus den restlichen 6149 Bildern (mindestens 20 pro Klasse).

2.3.2 Bibliotheken

1. **Keras**[1] ist eine hochleistungsfähige neuronale Netzwerk-API. Keras ist in Python[2] geschrieben wurde und auf TensorFlow[3] oder Theano[4] laufen kann. Noch dazu erleichtert Keras die Implementierung von neuronalen Netzwerken und ermöglicht schnelle Experimente zu ermöglichen.Für diese Arbeit benutzen wir die Version 2.2.5 von Keras.

2. **TensorFlow** ist eine End-to-End-Open-Source-Plattform für maschinelles Lernen. Es verfügt über ein umfassendes, flexibles Menge aus Tools, Bibliotheken und Ressourcen.Für diese Arbeit haben wir die Version 1.14.0 von TensorFlow verwendet.

[1] https://keras.io/
[2] https://www.python.org/
[3] https://www.tensorflow.org/
[4] http://deeplearning.net/software/theano/

3 Kompression von DNN

Die neueren maschinellen Lernmethoden verwenden immer tiefer neuronale Netze wie z.B *Xception(134 Layers),MobileNetV2(157 Layers), InceptionResNetV2(782 Layers)*, um Ergebnisse auf dem neuesten Stand der Technik zu erzielen. Aber die Verwendung von sehr tiefer NNs bringt mit sich nicht nur eine deutliche Verbesserung der Modellleistung, sondern auch einen bedeutenden Bedarf an Rechenleistung und an Speicherplatz, was der Einsatz solcher Modelle auf Echtzeitsystemen mit begrenzten Hardware-Ressourcen schwierig macht.Es wurden bisher mehrere Ansätze untersucht, um die dem NN zugewiesenen Ressourcen effizienter zu nutzen:

- Die Modellbeschneidung(*Network pruning*), die die redundanten und die nicht relevanten Verbindungen zwischen Neuronen entfernt.
- Die Destillation von NNs, die ermöglicht, die großen Modellen in kleinen zu komprimieren.
- Die Quantisierung von NN, die für die Darstellung von einzelnem Netzparameter weniger als 32 Bits nutzt.
- Huffman-Codierung, die eine komprimierte Darstellung des Netzwerks ermöglicht.

Im folgenden werden nur die Beschneidung, die Quantisierung von NN und die Anwendung von Huffman auf NN mehr eingegangen werden.

3.1 Pruning Network

Wie oben schon erwähnt, wird beim *Pruning* neuronaler Netzwerke versucht, unwichtige oder redundante Verbindungen oder komplette Neuronen aus dem Netzwerk zu entfernen, um ein Netz mit möglichst geringer Komplexität zu erhalten. Mit unwichtigen Verbindungen werden die Parameter (Gewichte und Bias) gemeint, die fast null sind, denn Parameter mit Nullwert haben keinen Einfluss auf das Output des Neurons, sie sind einfach überflüssig. Während oder nach dem Training gibt es mehrere Parameter, die nicht wirklich oder nicht zu viel zum Neuronenergebnis beitragen, obwohl sie keinen Nullwert haben, deshalb ist es zum Reduzieren der Netzwerkdichte notwendig, anderen Maßstäbe als den Nullwert anzulegen, um Verbindungen zu entfernen.

Das Pruning-Verfahren bietet einige Vorteile wie Reduzierung der Speicher- und Hardwarekosten, die Trainingsbeschleunigung , die schnellere Antwortzeit und das Verringern der Wahrscheinlichkeit der Overfitting(4.5.1). Es ist sehr wichtig zu beachten, dass die Anwendung vom Pruning-Verfahren auf ein NN nur Sinn macht, wenn das NN teilweise oder komplett trainiert ist, sonst macht das Pruning nur eine Reduktion der Anzahl der Netzwerkparameter.

Es gibt zwei Hauptszenarien für das Pruning von NN. Die erste besteht darin, die irrelevanten Verbindungen in einem komplett trainierten NN zu entfernen. Mit komplett trainierten NN wird gemeint, dass die erwünschte Genauigkeit schon erreicht ist. Im zweiten Szenario wird Pruning während des Trainings durchgeführt, das wird seht

oft als *iteratives Pruning* bezeichnet.Dabei wird vor Trainingsbeginn bestimmte Dinge festgelegt,wie z.B. ab wann wird das Netzwerk beschnitten und wie oft es durchgeführt werden soll. Das erste Szenario ist einfacher anzuwenden, denn man muss nur darauf warten, bis es keine Verbesserung der Genauigkeit des NN mehr gibt und dann Pruning auf das NN anwenden, aber damit verliert man großen Vorteile des Pruning, die die Beschleunigung des Trainings und Reduzierung der Overfitting-Wahrscheinlichkeit sind. Aus diesen Gründen wird in der Praxis das zweite Szenario bevorzugt, aber die richtigen Hyperparameter zu finden, ist kompliziert. Eine zu früh Beschneidung kann z.B. die Genauigkeit des NN zu sehr verschlechtern, denn es kann sein, dass eine Verbindung, die nur nach einer späteren Gewichtsanpassung zum Ergebnis eines Neurons hätte beigetragen können, entfernt würde, aber es bietet eine Beschleunigung des Trainings. Was eine zu spät Beschneidung angeht, haben wir fast die gleichen Nachteile wie im ersten Szenario und eine sehr häufiges Pruning kann das Training auch verlangsamen.Das ganze Prozess musst sehr oft leider mehrmals angewendet, um die richtigen Hyperparameter zu finden, sodass es sich wirklich nicht mehr lohnt. Ein graphischer Ablauf der Beschneidung ist in der Abbildung 20 zu sehen.Wenn wir zu viel auf einmal schneiden, könnte das Netzwerk so sehr beschädigt werden, dass es nicht mehr wiederhergestellt werden kann.

Die Hauptarbeit bei Pruning-Verfahren ist sicherlich, die guten Kriterien für die Bewertung der Wichtigkeit von Parametern zu finden und es ist vielleicht einer der Gründe, warum Pruning-Verfahren bisher nicht so populär ist, obwohl es immer noch zu schwierig ist, tiefe NNs beispielsweise auf mobile Geräten mit eingeschränkten Ressourcen durchzuführen.

Bisher gibt es viele Kriterien für die Bewertung der Wichtigkeit eines Parameters, die sich miteinander unterscheiden und je nach Anwendung Vor- und Nachteile aufweisen. Im Folgenden werden einige Kriterien vorgestellt.

- **Schwellenwert**
  Für die Bewertung der Wichtigkeit eines Parameters verwenden [7, Han et al] einen Schwellenwert θ , also alle Parameter mit einem Wert in $[-\theta, \theta]$ wenden eliminiert.So ein Kriterium macht das Pruning schneller und effizienter, weil es sehr einfach ist, die zu eliminierenden Parameter zu finden.Da nach dem Pruning immer ein Genauigkeitsverlust auftritt, muss das NN erneuert trainiert werden, um seine Genauigkeit wiederherzustellen. Aber dieser Ansatz hat viele Nachteile. Erstens muss der optimale Schwellenwert gefunden werden und dafür muss das ganze Prozess(Schwellenwert auswählen, NN beschneiden, Verlust vergleichen) mehrmals wiederholt werden, um nur den optimalen Schwellenwert zu finden, deshalb können wir nie sicher sein, dass wir den optimalen Schwellenwert gefunden haben.Zweitens wird eine große Reduktion der Rechenkosten nur in FCLs und nicht in ConvLs beobachtet[8]. Die modernen Architekturen von CNNs können also bezüglich der Rechenkosten aus dem Verfahren keinen Vorteil ziehen,denn sie bestehen am meistens nur aus Faltungschichten.Drittens muss spärliche Bibliotheken oder spezielle Hardware verwendet werden, damit die Bewertung des beschnitten NN effektiv wird.

- **Filter und Feature-Map Pruning**

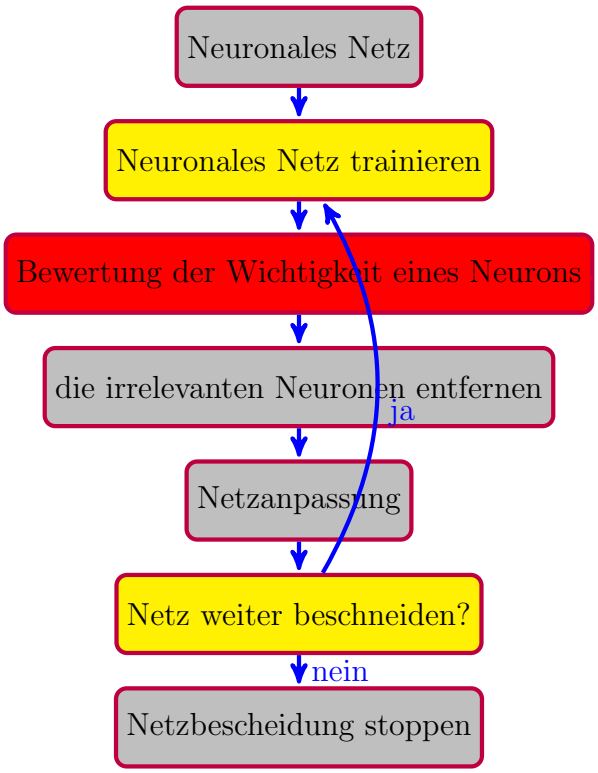

Abbildung 20: Netzbeschneidung während des Trainings

Anstatt die Gewichte in einem Filter elementweise zu entfernen,schlagen [8, Li et al] vor, das ganze Filter und die entsprechende Feature-Map zu entfernen.Dieses Vorgehen bringt mit sich im Vergleich mit dem oben vorgestellten Ansatz mehrere Vorteile.Es werden z.B. keine Bibliotheken, die eine Beschleunigung durch spärliche Operationen über CNNs ermöglichen, mehr benötigt.Noch dazu werden die Rechenkosten deutlich reduziert. Bei diesem Ansatz werden die weniger nützlichen Filter aus einem vollständig trainierten CNN entfernen. Zur Auswahl der zu entfernenden Filter wird zuerst die l_1-Norm(3.1) jedes Filter im NN berechnet und dann werden die m Filter mit der kleinsten l_1-Norm in jeder Schicht entfernen, wobei m ein Hyperparameter ist, der die Anzahl der zu löschenden Filter angibt.

$$\begin{aligned} ||F||_1 &= \sum_{i=1}^{h} \sum_{j=1}^{w} |F_{i,j}| \\ (w,h) &:= \text{ Breite und Höhe des Filters} \end{aligned} \tag{3.1}$$

Der Grund, warum nur die Filter mit einer kleineren l_1-Norm entfernt werden, liegt daran, dass sie neigen dazu, Feature-Maps mit geringen Aktivierungen im Vergleich zu den anderen Filtern in der selben Schicht zu erzeugen und das kann gut in der Abbildung 21 festgestellt werden. Wobei das Feature-Map links aus der Abbildung 21 ist das selbe mit dem aus Abbildung 4b und das Feature-Map rechts erhalten wir, indem wir das Filter aus Abb. 4a mit drei multiplizieren.

Noch interessanter an diesem Verfahren ist, dass das Pruning und das neue Trai-

Abbildung 21: Einfluss der Intensität des Filters auf Feature-Map

ning des Netzwerks auf einmal auf mehrere Schichten durchgeführt werden, was die Beschneidungszeit noch weiter beschleunigt und noch effizienter ist, wenn es um sehr tiefe Netzwerke wie *InceptionResNet* oder *GoogleNet* angeht. Zur Beschneidung von Filter auf mehrere Schichten kann man die zu entfernenden Filter auf jeder Schicht entweder unabhängig von anderen Schicht oder nicht auswählen. Sollte man die zu löschenden Filter auf jeder Schicht unabhängig von anderen Schichten bestimmen, so muss man mit höheren Rechenkosten rechnen, denn es werden Filter, die in vorherigen Schichten schon ausgenommen wurden, in der Berechnung der Summe der absoluten Gewichte noch miteinbezogen.Nach Li et al [8] ist die zweite Strategie nicht global optimal und kann trotzdem unter bestimmten Umständen zu besseren Ergebnissen führen. Die Abbildung 22 zeigt, wie die Entfernung eines Filters die Sichtausgabe beeinflusst.

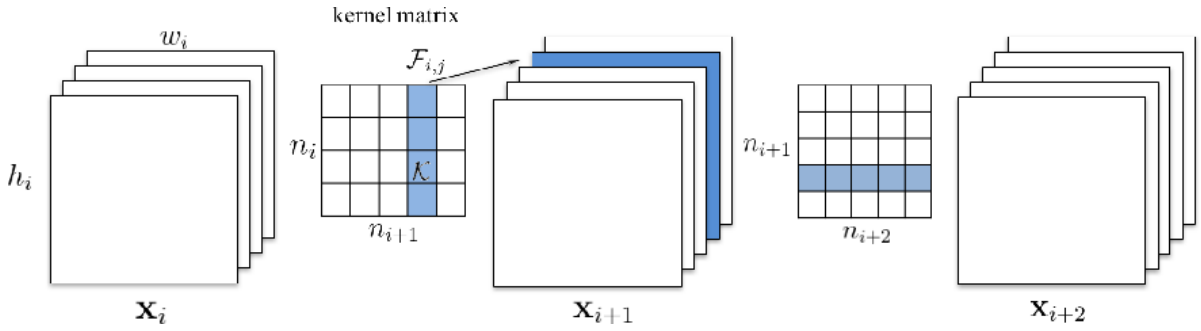

Abbildung 22: Das Beschneiden eines Filters führt zum Entfernen der entsprechenden Feature-Map und der zugehörigen Kernel in der nächsten Ebene[8].

- **Automatische Beschneidung**
  Die bisher beschriebenen Kriterien oder die meisten von ihnen fordern, dass das beschnittene Netzwerk noch trainiert wird, um die Endgewichte für die verbleibenden spärlichen Verbindungen zu lernen. Das ganze macht das Pruning-Verfahren noch schwieriger, denn es wird nur dann unterbrochen, wenn der Genauigkeitsverlust wirklich groß ist, was zu viel Zeit in Anspruch nimmt. Um dieses Problem zu lösen, schlagen *Manessi et al*[9] eine differenzierbare Technik vor, die es ermög-

licht, das Pruning durchzuführen, wenn die Gewichte des Netzwerks während der Trainingsphase angepasst werden und die optimalen Schwellwerte automatisch zu suchen. Dieses Verfahren ist inspiriert von dem von Han et al[7] und löst viele Probleme, die das Verfahren von *Han et al* nicht lösen könnten oder wegen der Art und Weise, wie sie das Pruning durchführen, entstanden.Erstens werden die Schwellenwerte während des Trainings wie die Gewichte auch gelernt, es kann also eine große Menge von unterschiedlichen Schwellenwerten ausprobiert werden und anstatt der selbe Schwellenwert auf alle Layers anzuwenden, wird jeder Schicht eine Schwelle zugewiesen. Da Nicht alle Layers gleich empfindlich gegenüber dem Pruning sind und die Verwendung eine selbe Schwelle auf jede Schicht davon ausgeht, dass sie sind, muss dieses Verfahren optimaler. Zweitens, anstatt die Trainingszeit zu erhöhen, weil auch neue Parameter gelernt werden müssen, wird sie reduziert,das liegt daran, dass die Netzwerkparameter irgendwann mehr oder weniger spärlich werden, was Feedforward- und Backpropagationzeit erheblich reduziert.Es ist wichtig zu betonen,dass das Netzwerk nur einmal trainiert werden muss, um eine selbe bzw. bessere Genauigkeit wie bzw. als die anderen Methoden zu erzielen.

Aufgrund seiner Automatisierung und Effizienz wird das Pruning in Zukunft sicherlich immer häufiger eingesetzt werden.

3.2 Quantisierung von neuronalen Netzwerken

Im Allgemein wird von Quantisierung gesprochen, wenn es versucht wird, sich den Werten einer großen Menge mit denen einer kleineren Menge zu nähern. Im Maschine Lernen (ML) ist die Quantisierung der Prozess der Transformation eines ML-Programms in eine approximierte Darstellung mit verfügbaren Operationen mit geringerer Genauigkeit. Es gibt eine zahlreiche Menge von Techniken, um ein ML-Programm zu quantisieren, aber wir werden in folgenden uns nur auf die bekanntesten Quantifizierungstechniken konzentrieren.

3.2.1 Matrixfaktorisierung

Die Matrixfaktorisierung versucht, eine Matrix durch die Singulärwertzerlegung(SVD) zu approximieren. Die Singulärwertzerlegung zur Annäherung an eine Matrix $A \in \mathbb{R}^{m \times n}$ verwendet eine Matrix $B \in \mathbb{R}^{m \times n}$ vom Rang $k \leq \min(m, n)$, siehe Gleichung(3.2), wobei U und V orthogonale Matrizen und S eine Diagonalmatrix, deren Diagonaleinträge Singulärwerte heißen und bei Betrachtung von oben nach unten monoton abnehmen, sind. Sollte man B direkt speichern, so hat man keine Kompression gemacht, sondern nur Informationen und Rechenzeiten verschwendet, denn die Matrizen A und B haben die gleiche Dimension, also liegt der Hauptvorteil von der Matrixfaktorisierung darin, wie die Matrix B gespeichert wird.

$$
\begin{aligned}
&A = USV^T \\
&B = \widehat{U}\widehat{S}\widehat{V}^T = U[:, :k]S[:k, :k]V[:k, :]^T \\
&||A - B||_F = \sqrt{\sum_{i=1}^{m}\sum_{j=1}^{n}(A-B)_{i,j}^2} := \text{Frobenius Norm}
\end{aligned}
\tag{3.2}
$$

Eigentlich werden $\widehat{U}, \widehat{S}$ und $\widehat{V}$ statt B gespeichert, damit wird $mk + kk + kn$ statt mn Speicherplatz verwendet und da $\widehat{S}$ Diagonalmatrix ist, kann auch einfach nur die Diagonaleinträge gespeichert werden, was zu einer Kompressionsrate von $\frac{mn}{k(m+n+1)}$ führt. Die Verwendung von Matrizen von kleinen Rang hebt die Tatsache hervor, dass es redundante Parameter in NN-Parametern gibt.Dies Redundanzeigenschaft wird ausgenutzt, um die Geschwindigkeit zu erhöhen[10, Denton et al].Im Sinne der Frobeniusnorm ist B die bestmögliche Approximation von A mit Singulärwertzerlegung durch eine Matrix von Rang k. Angenommen bildet die zu approximierenden NN-Parameter ein Bild, dann zeigt die Abbildung 23 ,wie man die NN-Parameter approximieren kann.

SW: Singulärwerte

Abbildung 23: Parameter Approximieren durch Matrixfaktorisierung

Wie man in der Abbildung 23 sieht, reichen relativ wenige Singulärwerte (ca. 5) schon aus, um die groben Konturen zu erkennen. Details erkennt man bei ca. 10 Singulärwerten schon. Generell wird das Bild mit mehr Singulärwerten schärfer.

3.2.2 Quantisierung mit weniger Bits(Low-bit Quantization)

Im Bereich des *Deep Learning* ist das Standard numerische Format für Forschung und Einsatz bisher 32-Bit Fließkommazahlen oder FP32, denn es bietet ein bessere Genauigkeit, aber die anderen Formaten wie 8-,4-,2- oder 1-Bits werden auch verwendet, obwohl sie mehr oder weniger ein Verlust an Genauigkeit aufweisen. Die Verwendung von weniger genauen numerischen Formaten hat nicht nur einen kleinen Verlust der Netzleistung zur Folge, sondern auch die Verwendung von deutlich reduzierter Bandbreite und Speicherplatz. Noch dazu beschleunigt die Quantisierung die Berechnungen, denn die ganzzahlige Berechnung zum Beispiel ist schneller als die Fließkommaberechnung.

Bei Quantisierung mit wenige Bits geht es mehr oder weniger um die Abbildung eine großen Bereiches auf einen kleinen und dazu werden zwei Hauptwerte benötigt: der

dynamische Bereich des Tensors und ein Skalierungsfaktor. Angenommen haben wir einen dynamischen Bereich $[0, 500]$ und einen Skalierungsfaktor$= 5$, dann ergibt sich der neue Bereich $[0, 100]$, es wird also Werte zwischen $[5k, 5(k + 1)]$ oder $[5k - 0.5, 5k + 0.5]$ auf $5k$ abgebildet. Es ist sinnvoller, die Skalierungsfaktors unter Berücksichtigung der Anzahl und der Verteilung der Werte in dynamischen Bereich des Tensors auszuwählen, sonst können zu viel Informationen verloren gehen.

Sobald ein anderes Format mit weniger Bits als FP32 verwendet, spricht man in ML von Quantisierung. Als Hauptvorteile von Quantisierung haben wir:Erstens wenn wir ein Modell mit FP32-Format durch das gleiche Modell mit 16-Bit Float(FP16), 8-Bit Integer(INT8) oder 4-Bit Integer(INT4) ersetzen, reduzieren wir den Speicherbedarf um die Hälfte,um ein Viertel bzw. um ein Achtel.Zweitens sind die Hardwares so programmiert, dass die integer Operationen im Vergleich zu FP32-Operationen schneller und energieeffizienter sind und drittens wird die Bandbreite durch die Verwendung von kleineren Modellen und dynamischen Werten stark reduziert.

Zur einer effizienteren Auswahl der Skalierfaktoren pro Schicht bzw. pro Filter ist es notwendig, Statistiken über das NN zu sammeln und das kann *offline* oder *online* gemacht werden. Bei der *Offline* Berechnung werden vor der Bereitstellung des Modells einigen Statistiken gesammelt, entweder während des Trainings oder durch die Ausführung einiger Epochen auf dem trainierten FP32-Modell und basierend auf diesen Statistiken werden die verschiedenen Skalierfaktoren berechnet und nach der Bereitstellung des Modells festgelegt.Bei dieser Methode besteht die Gefahr, dass zur Laufzeit die Werte, die außerhalb des zuvor definierten Bereichs auftreten, abgeschnitten werden, was zu einer Verschlechterung der Genauigkeit führen kann.Bei der *online* werden die *Min/Max*-Werte für jeden Tensor dynamisch zur Laufzeit berechnet. Bei dieser Methode kann es nicht zu einer Beschneidung kommen, jedoch können die zusätzlichen Rechenressourcen, die zur Berechnung der Min/Max-Werte zur Laufzeit benötigt werden, unerschwinglich sein.[17]

Es gibt zwei Quantifizierungsszenarien.Die erste ist das vollständige Training eines Modells mit einer gewünschten niedrigeren Bit-Genauigkeit(*bit precission*)(kleiner als 32 Bits).Das Training mit sehr geringer Genauigkeit ermöglicht ein potenziell schnelles Training und Inferenz, aber der Hauptproblem mit diesem Ansatz ist, dass Netzparameter nur bestimmte Werte annehmen können, so ist die Aktualisierung der Netzparameter bzw. das Backpropagation nicht mehr wohldefiniert [18]. Das zweite Szenario quantisiert ein trainiertes FP32-Netzwerks mit einer geringeren Bit-Genauigkeit ohne vollständiges Training.Im Allgemeinen gilt: Je geringer die Bitgenauigkeit, desto größer ist der Verlust der Genauigkeit und um diesen Leistungsabfall zu überwinden, wird sehr oft das NN erneuert trainiert oder wird auf eine hybride Quantisierung zurückgegriffen, die zur Quantisierung verschiedene Formaten z.B. INT8 für die Gewichte und FP32 für die Aktivierung gleichzeitig verwendet.

Vor kurzem haben [18, Yoni et al] zur Quantisierung das lineare Quantisierungsproblem als ein *Minimum Mean Squared Error* (MMSE) Problem formuliert und gelöst.Sie sind in der Lage, die trainierten Modelle zu quantisieren, ohne das NN erneuert trainieren zu haben, um seine Genauigkeit wiederherzustellen und benutzen dabei nur das INT4-Format. Obwohl diese Methode minimalen Verlust der Genauigkeit(*accuracy*) aufweist,

liefert sie Ergebnisse auf dem neuesten Stand der Technik und nach [18] weist dieser Ansatz einen geringeren Genauigkeitsverlust als alle anderen Quantisierungsverfahren auf.

Wie oben erwähnt, eine Quantisierung mit zu weniger Bit führt zu einem großen Genauigkeitsverlust, aber [18, Yoni et al] haben gezeigt, dass Die Quantisierung mit INT4-Format zu einem besseren Ergebnis führen kann. Das sollte daran liegen, dass sie fürs Approximieren eines Tensors, der gegenüber der Quantisierung sehr empfindlich ist, statt nur einen Tensor mehrere Tensors im INT4-Format benutzen.

3.3 Huffman Codierung

Die Huffman-Codierung ermöglicht eine verlustfreie Datenkompression, indem sie jeder einzelnen Dateneinheit eine unterschiedlich lange Folge von Bits zuordnet.Daraus folgt, dass eine gute Möglichkeit zur besseren Verwaltung der dem Modell zugeordneten Ressourcen ist:Erstmal das Netzwerk zu beschneiden, dann zu quantisieren und am Ende die Huffman-Codierung durchzuführen.

4 Experiment

4.1 Analyse der Ergebnisse mit Hilfe von Metriken

Nach dem Entwurf eines NNs muss es noch bewertet werden,um zu überprüfen, ob es unseren Erwartungen (Genauigkeit, Stabilität und Trainingszeit) entspricht. Diese Bewertung kann mit Hilfe von verschiedenen Metriken und einem Testdatensatz gemacht werden.Es ist zwingend erforderlich, dass der Datensatz in zwei (Training und Validierung) oder drei (Training, Validierung und Test) unterteilt wird, da es sonst nicht möglich sein wird, abzuschätzen, wie das Modell Konzepte aus dem Datensatz generalisiert, sondern vielmehr, wie es lernt, jedes Element des Datensatzes einer Klasse zuzuordnen und da das Modell trainiert ist, um die Fehlklassifizierung der Trainingsdaten zu reduzieren,verbessert sich die Netzwerkleistung für Trainingsdaten ständig,daher lohnt es sich nicht zur Abschätzung der Modellleistung die Trainingsdaten zu verwenden.

Metriken werden verwendet, um die Netzwerkleistung zu quantifizieren, und es gibt eine große Vielfalt davon. Die am meistens verwendeten Metriken sind die mittlere Genauigkeit(*mean accuracy*) und den Logarithmischen Verlust(*logarithmic loss*).

Die Mittlere Genauigkeit oder Klassifizierungsgenauigkeit ist die Anzahl der korrekten Vorhersagen im Verhältnis zu allen getroffenen Vorhersagen. siehe Gleichung(4.1). Der logarithmische Verlust sieht genauso wie das *Cross-entropy*(2.2). Wenn man die Abbildung 24 genau anschaut, stellt man fest, dass die Genauigkeit nach 60 Epochen flach bleibt, was bedeutet, dass die Netzwerkleistung konstant bleibt, d.h. das Netzwerk keine Verbesserung oder Verschlechterung aufweist.Aber wenn man sich die Validierungsverlustkurve (*validation loss curve*) betrachtet, stellt man fest, dass die Kurve nach 60

Epochen langsam steigt, was bedeutet, dass die Netzwerkleistung sich verschlechtert.

$$acc := \frac{Korrekte\ \ Vorhersagen}{Alle\ \ Vorhersagen} \tag{4.1}$$

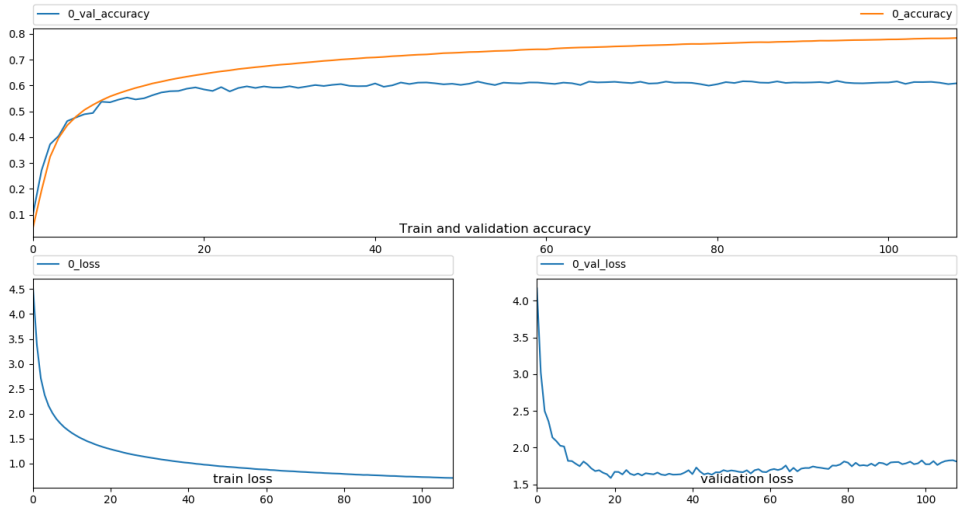

Abbildung 24: Vergleich zwischen der Genauigkeitskurve und der logarithmischen Verlustkurve.

Dieser großer Unterschied liegt daran, dass der logarithmische Verlust die Unsicherheit der Vorhersage in Betracht zieht und die Genauigkeit nicht. Nehmen wir an, dass ein CNN eine Klasse i zweimal hintereinander falsch klassifiziert;$0,25$ und $0,012$ Prozent zum ersten bzw. zweiten Mal; es ist klar, dass sich die Netzwerkleistung verschlechtert hat, aber die Genauigkeit bleibt gleich, während sich der logarithmische Verlust verschlechtert.

Die Genauigkeit ist keine zuverlässige Metrik für die tatsächliche Leistung eines Klassifikators, da sie bei einem unausgewogenen Datensatz irreführende Ergebnisse liefert (d.h. wenn die Anzahl der Beobachtungen in verschiedenen Klassen stark variiert). Dies funktioniert nur dann gut, wenn der Datensatz nahezu gleichmäßig auf die Klassen verteilt ist. Datenset nicht gleichmäßig verteilen

4.2 Entwurf eines neuronalen Faltunsnetzwerkes: TemkiNet.

Für den Entwurf unseres CNN mit geringem Speicherbedarf haben wir uns für die Verwendung von *Depthwise Convolution*4.2.1.2 und *Pointwise Convolution*4.2.1.3 -Schichten entschieden. Die Gründe für diese Entscheidung werden in den folgenden Abschnitten erläutert, in denen die am häufigsten verwendeten Faltungsschichten beschrieben werden, siehe und für unseren Baustein (*Building block*) haben wir uns viel von *Xception*- und *MobileNet*-Bausteinen inspirieren lassen, siehe 4.2.2.

4.2.1 Art der Faltungsschichten.

Heutzutage werden am meisten nur Filter der Größe 1×1 und 3×3 und nicht größer verwendet, obwohl größere Filter globale Informationen effizienter entnehmen und so zu besseren Ergebnissen kommen können. Dafür gibt es viele Gründe. Erstens sind die Berechnungen mit kleinerer Filter viel schneller als mit größerer Filter. Zweitens kann ein ConvL mit einer großen Filtergröße durch mehrere aufeinanderfolgende ConvLs mit einer kleineren Filtergröße ersetzt werden und dabei werden sogar die Anzahl der benötigten Parameter deutlich reduziert. Sollte man z.B. ein 5×5 Filter auf eine Eingabe von Tiefe d angewendet, so braucht man $5\times5\times d$ Gewichte, um ein Feature-Map zu erzeugen. Nimmt man hingegen zwei aufeinanderfolgende ConvLs mit 3×3 Filtern, so braucht man nur $2(3 \times 3 \times d)$ Gewichte, um ein Feature-Map zu erzeugen. Drittens hat man bei kleinen Filtern nur eine langsame Reduzierung der Bilddimension, was den Entwurf von sehr tiefer CNNs wie *InceptionResNet* ermöglicht. Viertens können kleine Filter sehr lokale Merkmale extrahieren, so dass einfache und komplexe Informationen gleichzeitig erfasst werden.Die Anzahl der extrahierten Features ist enorm und werden gefiltert, wenn man tiefer im Netzwerk geht.

Der Absatz(2.2.1.2) behandelte mehr über die Faltungsoperation bei einem Eingang mit einem Kanal. Im Folgenden werden verschiedene Arten beschrieben, wie die Faltungsoperation an einem Eingang mit mehreren Kanälen durchgeführt werden kann. Für die Erklärung von Konzepten wird folgendes als Eingabe der Faltungsschicht betrachtet.

$$I = \begin{cases} \text{Filtergröße: } F := (F_w, F_h) & n_f\text{: Anzahl von Filtern} \\ \text{Input\_size: } W_{in} \times H_{in} \times D_{in} & P\text{: die Anzahl der Nullauffüllung(Padding)} \end{cases}$$

4.2.1.1 Standard Convolution

Die Standardfaltungsschicht funktioniert genau wie in der Abbildung(25).Für eine Eingabe I erzeugt die Standardfaltungsschicht Feature-Maps der Größe $(W_{out}, H_{out}, 1)$, wobei W_{out} und H_{out} wie in der Gleichung 4.2 berechnet werden.Für die Berechnung eines Feature-Map wird ein $(F_w \times F_h \times D_{in})$-Filter auf den Input angewendet. Dabei wird zuerst für jeden Kanal $I_i := I[:, :, i]$ die Faltungsoperation mit dem Filter $F_i := F[:, :, i]$ durchgeführt und dann werden die Ergebnisse jeder Faltungsoperation aufsummiert, um das Feature-Map zu bilden.

$$\begin{aligned} W_{out} &= \frac{W_{in} - F_w + 2P}{S} + 1 \\ H_{out} &= \frac{H_{in} - F_h + 2P}{S} + 1 \\ D_{out} &= n_f \end{aligned} \tag{4.2}$$

Die Berechnungskosten der Standardfaltung für eine Eingabe I unter der Annahme, dass die Schrittgröße eins und Padding berechnet werden, entspricht:

$$F_w \times F_h \times D_{in} \times n_f \times W_{in} \times H_{in} \tag{4.3}$$

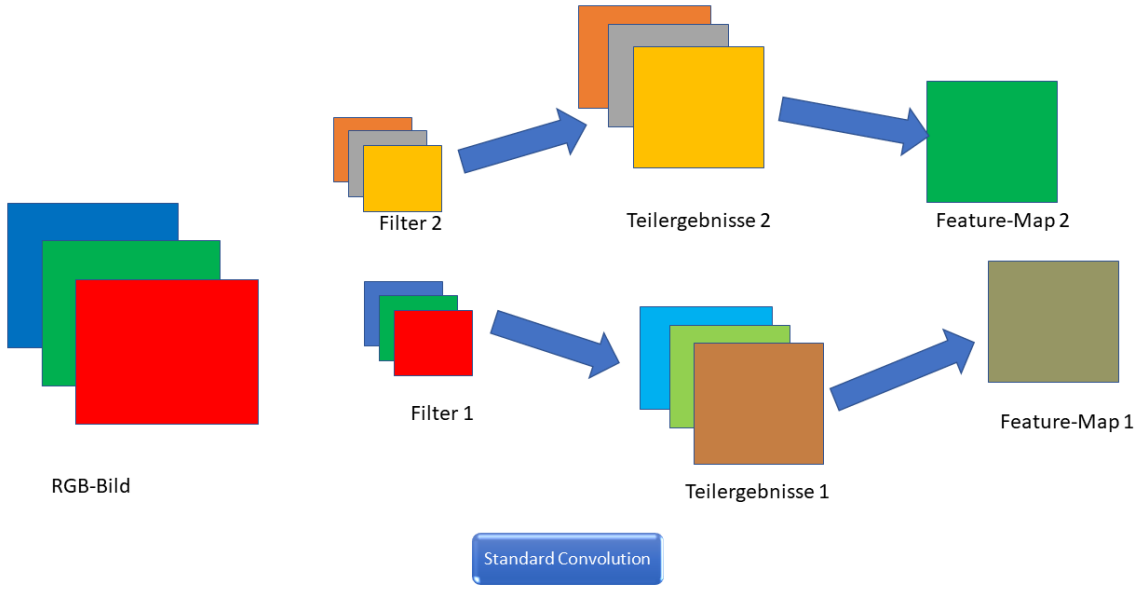

Abbildung 25: Standardfaltungsschicht mit zwei Filtern auf ein Farbbild.

4.2.1.2 Depthwise Convolution

Genau wie die Standardfaltung funktioniert die *Depthwise Convolution*, außer dass die Teilergebnisse von Standardfaltung schon der Feature-Maps von der *Depthwise Convolution* entsprechen.Festzustellen ist, dass die Anzahl von Feature-Maps immer proportional zur Anzahl der Kanäle des Inputs sein muss.Damit die Anzahl von Feature-Maps der *Depthwise Convolution* mehr als die Anzahl der Kanäle des Inputs ist, wird ein so genannter Tiefen-Multiplikator (*Depth_multiplier*) $\alpha \in \mathbb{N}_{\geq 1}$ definiert. Der Tiefen-Multiplikator gibt an, wie viele Filter pro Kanal verwendet werden müssen. Die Abbildung(26) zeigt die Anwendung der *Depthwise Convolution* mit einem $\alpha = 2$ auf ein Farbbild. Die *Depthwise Convolution* hat für eine Eingabe I unter der Annahme, dass Schrittgröße eins und Padding berechnet werden, einen rechnerischen Aufwand von:

$$F_w \times F_h \times D_{in} \times W_{in} \times H_{in} \tag{4.4}$$

Wenn man die Gleichungen 4.3 und 4.4 betrachtet, stellt man schnell fest, dass *Depthwise Convolution* im Vergleich zur Standardfaltung äußerst effizient ist. Der Nachteil von *Depthwise Convolution* ist, dass jede generierte Feature-Map nur einen Kanal in Betracht zieht, was bedeutet, dass Kanäle, die nicht so viele wichtige Informationen enthalten, die gleiche Bedeutung erhalten wie Kanäle, die so viele Informationen enthalten.

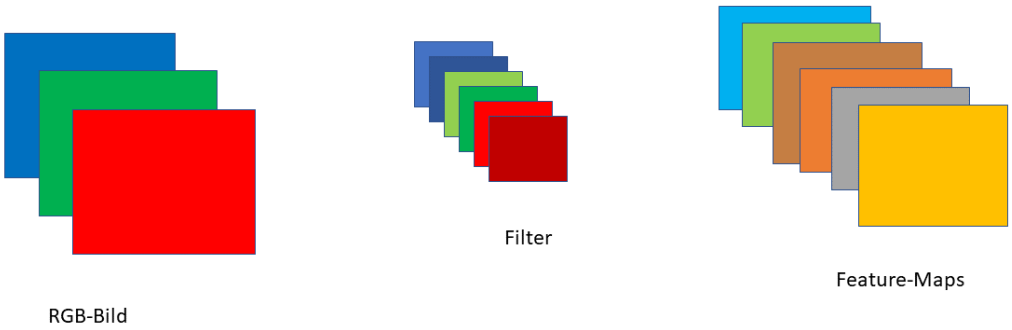

Abbildung 26: Depthwise Convolution auf ein Farbbild.

4.2.1.3 Pointwise Convolution

Die *Pointwise Convolution* funktioniert genau wie die Standardfaltung, nur dass die Größe der Filter und die Schrittgröße in der *Pointwise Convolution* jeweils immer $(1, 1)$ sind. Also jedes erhaltene Teilergebnis ist nur die Skalierung eines Eingangskanals. Die *Pointwise Convolution* hat für eine Eingabe I einen rechnerischen Aufwand von:

$$D_{in} \times W_{in} \times H_{in} \times n_f \tag{4.5}$$

Die Hauptidee bei der Verwendung der *Pointwise Convolution* ist es, die Korrelation zwischen den Eingangskanälen zu finden, oder lineare Kombinationen zu lernen ,und erleichtert die Reduzierung und Erhöhung der Anzahl der Kanäle, wenn es zu viele oder zu wenige Feature-Maps gibt. Es kann jedoch mit *pointwise Convolution* keine Features extrahiert werden.

4.2.1.4 Depthwise Separable Convolution

Die *Depthwise Separable Convolution*(DSC) besteht aus einer *Depthwise Convolution*, gefolgt von einer *Pointwise Convolution*.Sie kann also Features schneller filtern und kombinieren als die Standardfaltung. Die DSC hat einen rechnerischen Aufwand von:

$$F_w \times F_h \times D_{in} \times W_{in} \times H_{in} + D_{in} \times W_{in} \times H_{in} \times n_f \tag{4.6}$$

Von 4.3 und 4.6 aus sieht man, dass die DSC weniger Berechnung als Standardfaltung benötigt, und zwar $\frac{1}{n_f} + \frac{1}{F_w \times F_h}$. Da die DSC zu wenig Parameter verwendet, werden

die CNN, die die DSC verwenden, sehr oft als quantisiert bezeichnet.Die DSC ersetzt langsam und sicher die Standardfaltung und das kann mit *Xception* und *MobileNet* beobachtet werden.

4.2.2 Faltende neuronale Netzwerke

Obwohl die gleichen Bausteine, Schichten oder Hyperparameter verwendet werden, um verschiedene CNNs aufzubauen und zu trainieren, macht die Architektur den größten Unterschied beim Vergleich von CNNs bezüglich der Netzwerkleistung.Im Nachfolgenden wird zuerst einige bekannte CNNs, dann unser eigenes CNN vorgestellt und schließlich wird die Leistung der Netzwerke verglichen.

4.2.2.1 AlexNet

Wie in 2.1.4 schon erwähnt, wurde AlexNet von *Krizhevsky* et al [20] im Jahr 2012 entwickelt. AlexNet hat etwa 60 Millionen Parametern und etwa 650.000 Neuronen, besteht aus fünf ConvLs, von denen einige von Max-PooLs gefolgt sind, und drei FCLs(siehe Abbildung 27) [20]. Vor AlexNet gab es keine CNNs mit so vielen Schichten, noch interessanter sind die Techniken zur Verbesserung der Leistung von *AlexNet*:

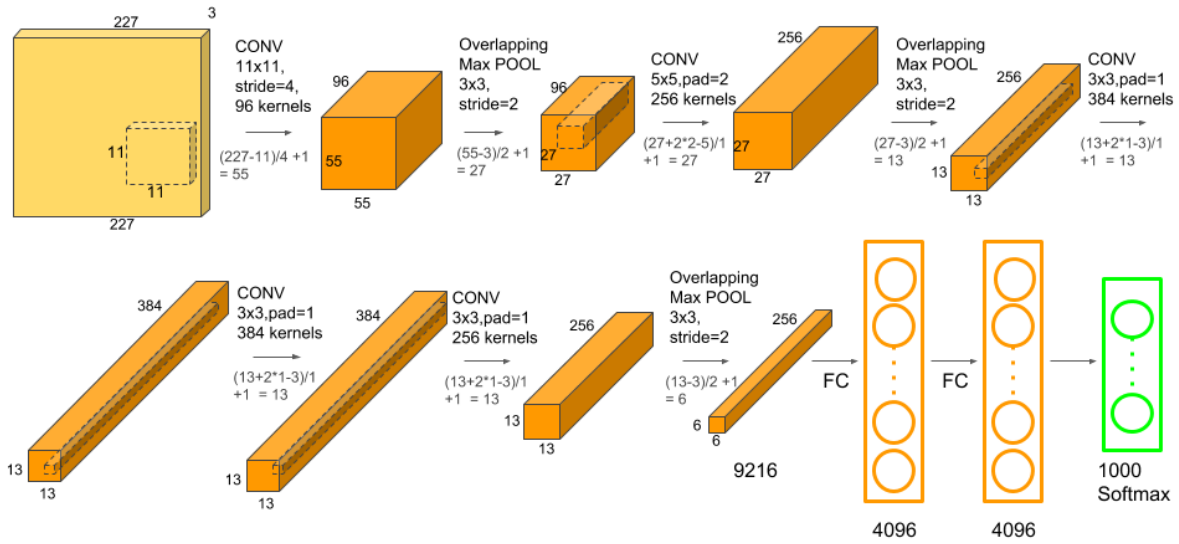

Abbildung 27: AlexNet Architektur source

- **ReLU**: Vor AlexNet waren *tanh* und *sigmoid* die am häufigsten verwendeten Aktivierungsfunktionen, aber wegen ihrer Sättigung bei hohen oder sehr niedrigen Werten und der Tatsache, das sie in diesen Bereichen eine Steigung nahe bei null haben, verlangsamen sie stark die Gewichtsanpassungen, was nicht der Fall bei

ReLU ist, das eine Steigung gleich null nur bei negativen Werten und bei positiven höheren Werte nicht nahe bei null hat. Noch dazu sind *ReLU* und seine Ableitung schneller zu berechnen als die Sigmoid Funktion und das macht einen bedeutenden Unterschied in der Trainings- und Inferenzzeit für CNN aus.Ein anderer Vorteil von *ReLU* ist die Sparsamkeit, die entsteht, wenn die Aktivierung von Neuron kleiner als 0 ist.

- **Überlappendes Pooling**: Die normalen PooLs funktioniert wie in 2.2.1.4 ($pool\_size = stride$), aber die Überlappenden verwenden einfach eine Schrittgröße kleiner als das $pool\_size$.Nach [20] verbessern die überlappenden PooL die Netzgenauigkeit und macht das Netz gegenüber die Überanpassung robuster.

- **Dropout**: Ein anderer Vorteil von *AlexNet* ist die Verwendung von Dropout(4.5.1) in FCLs, das sich heute als die beste oder eine der besten Regulierungsmethoden erweist.

AlexNet kann aufgrund seiner Größe($\sim$ 240MB) nicht immer auf Systemen mit begrenztem Speicherplatz eingesetzt werden, deshalb ist man seit *AlexNet* ständig auf der Suche nach neuen Architekturen, die weniger Parameter und also weniger Speicherplatz brauchen, und die die Ergebnisse auf der Stand der Technik erreichen. Es ist sicherlich in diesem Zusammenhang, dass viele neue effiziente Modelle wie *SqueezeNet*, *Xception* und *MobileNet* entstanden sind.

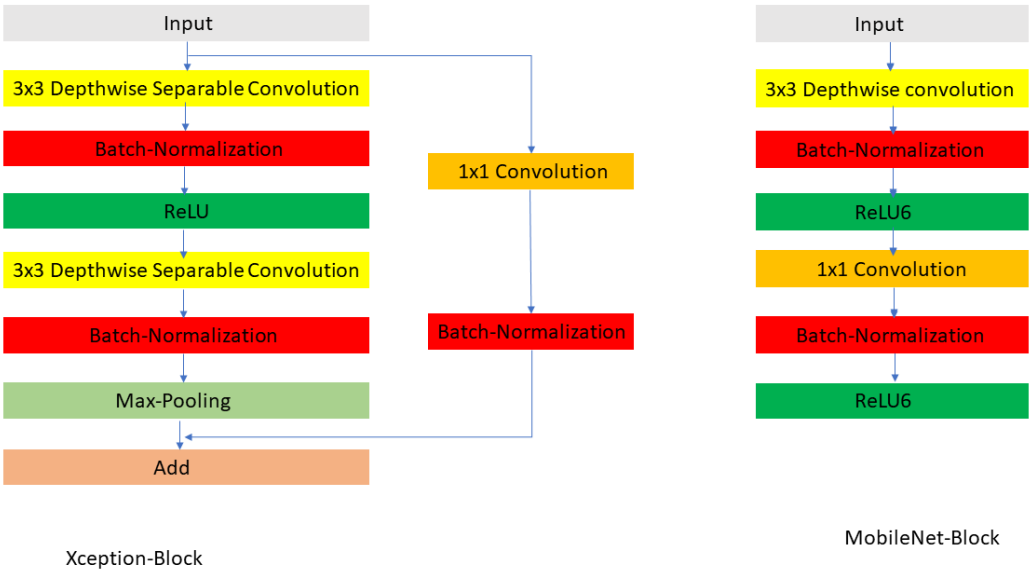

Abbildung 28: Xception- und MobileNet-Baustein.

4.2.2.2 Xception

Xception([23]) basiert auf *InceptionV3*([24]). Das Xception-Model ersetzt alle Inception-Blöcke durch Xception-Blöcke (28). In einem Inception-Block werden mehrere Filter unterschiedlicher Größe separat auf eine Eingabe angewendet und die Ergebnisse jeder Faltungsoperation werden zusammengeführt.Die Verwendung von mehreren Filtern unterschiedlicher Größe ermöglicht eine schnellere Feature-Extraktion, da die kleinen Filter sich mit der Extraktion von sehr lokalen Features beschäftigen, während die großen Filter sich mit der Extraktion von globalen Features beschäftigen. Aus der Abbildung Vergleich Graph sieht man an, dass Xception im Vergleich zu anderen Modellen relativ schnell ist.Die Anzahl der Parameter von Xception ist leider immer noch enorm ($\sim$ 22.000.000) .

4.2.2.3 MobileNet

MobileNet([25]) wie *Xception* macht die *Depthwise Separable Convolution* zunutze.Wie in der Abbildung(28) zu sehen ist, wurden aber *Batch-Normalisierung und ReLU6*-Layers vor und nach der 1×1 Faltungschicht hinzugefügt, was eine schnelle Feature-Extraktion ermöglicht und die *ReLU6* Aktivierung erhöht die Nichtlinearität der Entscheidungsfunktion. *MobileNet* nutzt etwas $\sim$ 3.5 Millionen Parameter, was mindestens sechsmal weniger als die Parameteranzahl von *Xception* ist, was auch eine bessere Inferenz ermöglicht.

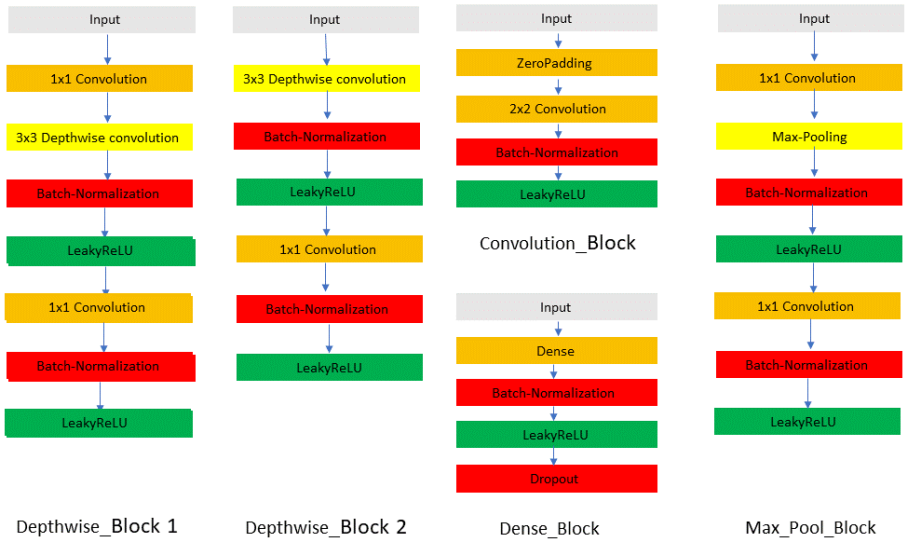

Abbildung 29: TemkiNet-Bausteine.

4.2.2.4 TemkiNet

Inspiriert von den soeben beschriebenen CNNs haben wir *TemkiNet* entwickelt, das aus 1.2 Millionen Parametern besteht,was im Vergleich zum anderen NNs recht gering ist. Die Bausteine von *TemkiNet* sind in der Abbildung 29 zu entnehmen. Anstatt die Anzahl der Neuronen jedes Mal zu erhöhen, wenn tiefer ins Netzwerk eingedrungen wird, wie es bei Standardnetzwerken der Fall ist,wird bei *TemkiNet* die gleiche Anzahl von Neuronen für jede ConvL verwendet. d.h alle ConvLs erzeugen die gleiche Anzahl von Feature-Maps.Wegen den zu geringen Anzahl von Parameter von *TemkiNet* können wir von ihm nur eine schlechte Leistung erwarten, aber die durchgeführten Experimente haben gezeigt, dass es beeindruckende Ergebnisse erzielen kann, die sogar die von konventionellen Netzwerken übertreffen könnten.Ein kurzer Überblick über die Architektur von *TemkiNet* kann in der Tabelle 2 verschafft werden.

Da jede Schicht die gleiche Anzahl von Feature-Maps erzeugt, ist die Implementierung von *TemkiNet* ziemlich einfacher, denn die die Anzahl von Feature-Maps pro Schicht kann einfach als einen Hyperparameter übergeben werden,was es noch einfacher macht, den Einfluss der Anzahl von Neuronen pro Schicht auf die Netzwerkleistung zu untersuchen.

Block	Schrittgröße	Outputgröße
conv_Block	2×2	$(100, 100, 101)$
Depthwise_Block 1	2×2	$(50, 50, 101)$
Depthwise_Block 1	1×1	$(50, 50, 101)$
Depthwise_Block 1	2×2	$(25, 25, 101)$
2×Depthwise_Block 1	1×1	$(25, 25, 101)$
Depthwise_Block 1	2×2	$(12, 12, 101)$
3×Depthwise_Block 1	1×1	$(12, 12, 101)$
Depthwise_Block 1	2×2	$(6, 6, 101)$
4×Depthwise_Block 1	1×1	$(6, 6, 101)$
Depthwise_Block 1	2×2	$(3, 3, 101)$
2×Depthwise_Block 1	1×1	$(3, 3, 101)$
Flatten	/	909
Dense_Block	/	1024
FC		101

Tabelle 2: TemkiNet Architektur mit 101 Feature-Maps pro ConvL

Basierend auf der Architektur von *TemkiNet* haben wir mehrere Varianten von *TemkiNet* entwickelt, die weniger Parameter benötigen und einen vernachlässigbaren Genauigkeitsverlust aufweisen. Im Laufe dieser Arbeit werden die verschiedenen Versionen allmählich vorgestellt.

4.2.3 Vergleich zwischen CNNs

Die Tabelle 3 stellt die Leistungen von verschiedenen CNNs dar.Festzustellen ist, dass die CNN im Laufe der Zeit immer kleiner werden.Dabei ist die große Enttäuschung, dass zum einen *AlexNet* , das älteste CNN, die beste Leistung erzielt hat und zum anderen die Gesamtleistung nicht gut ist.

CNN	# Parameter	Epoche	Genauigkeit
AlexNet	22.037.233		26.60%
Xception	21.068.429		26.20%
MobileNet	3.332.389		18.09%
TemkiNet	1.418.817		26.01%

Tabelle 3: Vergleich zwischen CNN.

4.3 Verbesserung der Leistung eines Convolution Neuronalen Netzwerks

Es ist sehr wichtig, eine geeignete Architektur zu finden, aber leider reicht es nicht aus, um zu gewährleisten, dass sehr gute Ergebnisse erzielt werden. Im Folgenden werden wir einige Methoden, Techniken oder Hyperparameter untersuchen, die zur Verbesserung der Netzwerk-Performance eingesetzt werden können.

4.3.1 Datenvermehrung (Data Augmentation).

Ein großer Datensatz ist entscheidend für die Leistung tiefer neuronaler Netzwerke und sagen, dass ein Datensatz groß oder ausreichend für das Training eines CNN ist, hängt nur von der Parameteranzahl des CNN ab. Da die CNNs, die gute Leistungen erzielen, leider aus mehreren Millionen Parametern bestehen, ist für jedes Problem des maschinellen Lernens nahezu unmöglich, ausreichende Daten zu finden.Anstatt immer neue Daten zu sammeln, um die Netzwerkleistung zu verbessern, können wir die Leistung des Modells verbessern, indem wir neue Daten aus bestehenden Daten generieren.
Die populären Techniken oder Transformationen zur Vermehrung des Datensatzes sind die horizontalen oder vertikalen Spiegelungen, Drehungen, Skalierungen, Zuschneiden und die Parallelverschiebungen.

Für diese Arbeit wurden drei Ansätze zur Erhöhung des Datensatzes verwendet: Der erste Ansatz besteht darin vor dem Training neue Daten zu erzeugen. Dabei werden die oben erwähnten Techniken vor dem Training angewendet, um zum Trainingszeitpunkt und zur Testzeit einen großen Datensatz zu haben. Der zweite Ansatz verwendet keinen größeren Datensatz, sondern immer das Original. Wenn Samplen aus dem Datensatz in das Netzwerk eingeführt werden, werden sie entweder transformiert oder direkt übertragen.Die *KERAS* Funktion *ImageDataGeneerator* bietet die Möglichkeit, Daten zur Laufzeit umzuwandeln. Vor dem Trainingsanfang werden alle Transformationen, die für jede Sample aus dem Datensatz durchgeführt werden können, definiert und beim

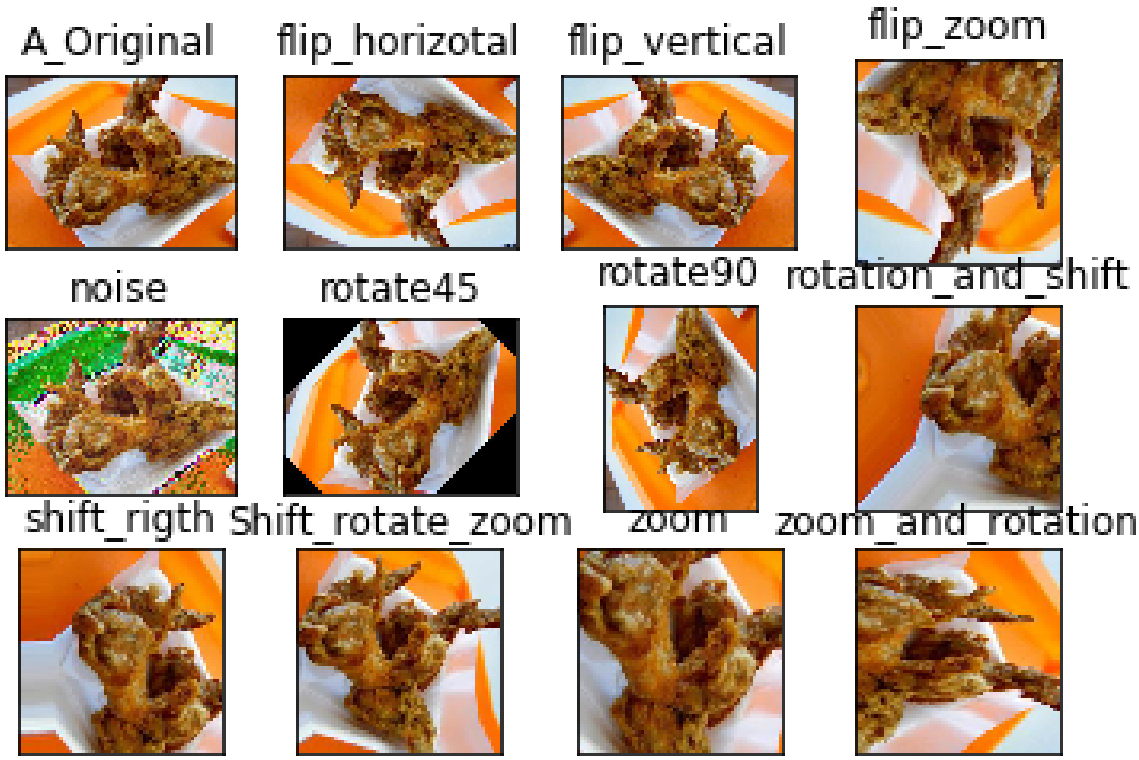

Abbildung 30: Anwendung von *ImageDataAugmentation*-Funktion

Einspeisen einer Sample ins Netzwerk wird eine oder gar keine Transformation zufällig auf die Sample durchgeführt. Die Netzwerkeingabe ändert sich also ständig. Das interessanteste an *ImageDataGenerator* ist, dass es mehrere Transformationen gleichzeitig anwenden kann(siehe Abbildung 30). Der dritte Ansatz ist die gleichzeitige Anwendung der beiden anderen Ansätze.

Je mehr Daten verfügbar sind, desto effektiver können die CNNs sein. Es ist also mehr als wichtig über eine große Datenmenge zu verfügen. Leider können die gesammelten Datensätze nicht alle mögliche Szenarios des reellen Lebens abdecken,deshalb ist es auch bedeutend, CNN mit zusätzlichen synthetisch modifizierten Daten zu trainieren. Die CNNs funktionieren glücklicherweise besser oder immer gut, solange nützliche Informationen durch das Modell aus dem ursprünglichen Datensatz extrahiert werden können, selbst wenn die erzeugten Daten von geringerer Qualität sind.

Obwohl der erste und dritte Ansatz mehr Daten haben und daher bessere Ergebnisse liefern sollten, zeigt die Abbildung 31, dass die drei Ansätze zu demselben Ergebnis($\sim$ 62% Genauigkeit) führen.Das liegt daran, dass die Transformationen, die zur Erweiterung des Datensatzes vor Trainingsbeginn verwendet werden, auch während des Trainings verwendet werden, was dazu führt, dass ein Bild in derselbe Epoche mehrmals ins Netzwerk eingespeist werden kann, was das Netzwerk dazu bringt, diesem Bild mehr Bedeutung zu verleihen.Eine direkte Folge davon ist die Überanpassung des ersten und dritten Ansatzes, die in der Abbildung 31 zu beobachten ist.Dennoch der erste und

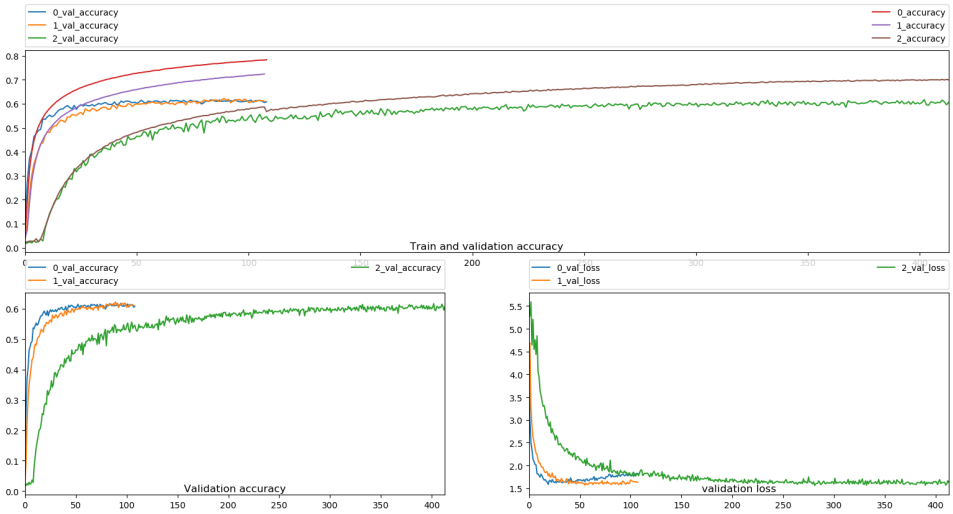

0: Erster Ansatz :
1: Dritter Ansatz 2: Zweiter Ansatz
Imagegröße: (100, 100,3) Lernrate: = 0.001

Abbildung 31: Vergleich von Datenvermehrungstechniken

dritte Ansatz reduzieren im Vergleich zum zweiten deutlich die benötigte Trainingszeit, während der zweite Ansatz das CNN robuster macht.

Mit dem zweiten Ansatz haben wir das Experiment(4.2.3) wiederholt und die Ergebnisse sind in der Tabelle 4 zu sehen.Jetzt wird festgestellt, dass die modernen CNNs nicht nur die Oberhand über die ältere behalten, sondern auch, dass sie mit der Datenvermehrung eine höhere Leistungsverbesserung haben und das sollte daran liegen, dass die modernen CNN zu wenige Parameter zu optimieren haben, was es leichter macht, lokale oder globale Minima zu finden.Noch dazu ist die Leistung von modernen CNNs mehr als verdoppelt und das beste Ergebnis wird mit *TemkiNet* erreicht.

CNN	# Parameter	Genauigkeit ohne D.A	Genauigkeit mit D.A	Verbesserung
AlexNet	22.037.233	26.60%	31.10%	4.5%
Xception	21.068.429	26.20%	53.25%	27.05%
MobileNet	3.332.389	18.09%	46.79%	28.70%
TemkiNet	1.418.817	26.01%	61.83%	35.83%

Tabelle 4: Vergleich zwischen CNN mit Datenvermehrung.

4.3.2 Aktivierungsfunktion.

Wie in Absatz 2.2.1.3 gesehen, ist es vorteilhaft, wenn eine Aktivierungsfunktion bestimmte Eigenschaften besitzt.Nach der Tabelle 5 erzielen die Variante von *ReLU* die besten Ergebnisse und die Experimente zeigen, dass die *LeakyReLU*-Funktion nicht nur das beste Ergebnis gibt, sondern auch am stabilsten und schnellsten ist.

Aktivierung	Genauigkeit	#Parameter
Tanh	06.83%	1.418.817
ReLU6	58.99%	1.418.817
PReLU	59.70%	3.976.757
LeakyReLU	61.83%	1.418.817

Tabelle 5: Vergleich der Aktivierungsfunktionen.

4.3.3 Optimierer.

Die Wahl des Optimierungsalgorithmus für ein CNN kann den Unterschied zwischen guten Ergebnissen in Minuten, Stunden und Tagen ausmachen.Zum besserer Anwendung der Gradientenabstiegsverfahren wurden mehrere Optimierte Lernverfahren entwickelt. Im folgenden wird ein kurzer Einblick über die bekanntesten Lernverfahren(*Optimizer*) gegeben werden. Fast alle heutige Optimierer haben SGD(*Stochastic Gradient Descent*) als Vorfahren und der Hauptnachteil von SGD ist, dass es die gleiche Lernrate für die Anpassung aller Netzwerkparameter verwendet und diese Lernrate wird auch während des Trainings nie geändert.

1. **Adaptive Gradient Algorithm (AdaGrad)**
   AdaGrad bietet während des Netztrainings nicht nur die Möglichkeit, die Lernrate zu verändern, sondern auch für jeden Parameter eine geeignete Lernrate zu finden. Die AdaGrad-Aktualisierungsregel ergibt sich aus der folgenden Formel:

$$\begin{aligned} \alpha_t &= \sum_{i=1}^{t} (g_{i-1})^2 \quad \theta_{t+1} = \theta_t - \eta_t g_t \\ \eta_t &= \frac{\eta}{\sqrt{\alpha_t} + \epsilon} \end{aligned} \tag{4.7}$$

$$\text{Voreingestellte Parameter}(KERAS): \quad \alpha_0 = 0.0 \quad \eta = 0.001 \quad \epsilon = 10^{-7}$$

   Dabei wird am Trainingsanfang eine Lernrate für jeden Parameter definiert und im Trainingsverlauf separat angepasst. Dieses Verfahren eignet sich gut für spärliche Daten, denn es gibt häufig auftretende Merkmale sehr niedrige Lernraten und seltene Merkmale hohe Lernraten, wobei die Intuition ist, dass jedes Mal, wenn eine seltene Eigenschaft gesehen wird, sollte der Lernende mehr aufpassen. Somit erleichtert die Anpassung das Auffinden und Identifizieren sehr voraussehbarer,

aber vergleichsweise seltener Merkmale.[15].Wie in der Gleichung (4.7) festzustellen,nach einer bestimmten Anzahl von Iterationen haben wir keine Verbesserung der Netzleistung, denn je größer t wird, desto kleiner η_t wird und irgendwann wird η_t so klein, dass $\eta_t g_t$ fast gleich null ist.

2. **Root Mean Square Propagation(RMSProp)**
RMSProp wie AdaGrad findet für jeden Parameter eine geeignete Lernrate und zur Anpassung der Netzparameter basiert der RMSProp Optimierer auf den Durchschnitt der aktuellen Größe der Gradienten statt auf der Summe der ersten Moment wie in AdaGrad.Da $E[g^2]_t$ nicht schneller als $\alpha_t(4.7)$ ansteigt, wird die radikal sinkenden Lernraten von Adagrad deutlich verlangsamt.Die Parameteranpassungen richten sich nach der folgenden Gleichung:

$$\begin{aligned} E[g^2]_t &= \alpha E[g^2]_{t-1} + (1-\alpha) g_t^2 \\ \theta_{t+1} &= \theta_t - \frac{\eta}{\sqrt{E[g^2]_t + \epsilon}} g_t, \quad \epsilon \approx 0 \end{aligned} \tag{4.8}$$

Der RMSProp funktioniert besser bei Online- und nicht-stationären Problemen.

3. **Adaptive Moment Estimation(Adam)**
Der Adam[16] Optimierer ist auch ein adaptiver Algorithmus,der die ersten und zweiten Momente der Gradienten schätzt, um individuelle adaptive Lernraten für verschiedene Parameter zu berechnen. Adam weist die Hauptvorteile von AdaGrad, das mit spärlichen Gradienten gut funktioniert, und RMSProp, das einige Probleme von AdaGrad löst und das für nicht-konvexe Optimierung geeignet ist,auf.Wie die Parameteranpassung von Adam Optimizer genau funktioniert, ergibt sich aus der folgenden Gleichung:

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1-\beta_1) g_t, \quad \widehat{m}_t = \frac{m_t}{1-\beta_1^t} \\ v_t &= \beta_2 v_{t-1} + (1-\beta_2) g_t^2, \quad \widehat{v}_t = \frac{v_t}{1-\beta_2^t} \\ \theta_{t+1} &= \theta_t - \frac{\eta}{\sqrt{\widehat{v}_t} + \epsilon} \widehat{m}_t \end{aligned} \tag{4.9}$$

$$\text{Voreingestellte Parameter}(KERAS): \begin{array}{ll} \beta_1\text{: } 0.9 & \beta_2\text{: } 0.999 \\ \eta\text{: } 0.001 & \epsilon\text{: } 10^{-7} \end{array}$$

Zu weiteren Vorteile der Nutzung von Adam gehört auch seine Einfachheit zur Implementierung, effizienter Nutzung der Speicherplatz und seine Invarianz zur diagonalen Neuskalierung der Gradienten a revoir.

4. **Vergleich.**
Die Ergebnisse in der Tabelle 6 stimmen perfekt mit der soeben beschriebenen Theorie überein, die aussagt, dass die besten Ergebnisse mit dem *Adam*-Optimierer

erzielt werden sollen. Wir stellen auch fest, dass Optimierer auf eine Veränderung der Lernrate unterschiedlich reagieren können; wenn bestimmter Optimierer(*Adagrad und SGD*) nur mit großer Lernrate besser funktionieren, funktionieren die andere(*rmsprop, und Adam*) nur mit kleiner Lernrate besser.

Optimierer	Epoche	Lernrate	Genauigkeit
Adagrad	624	0.001	23.21%
Adagrad	136	0.005	51.65%
SGD	2283	0.0001	45.20%
SGD	846	0.001	55.01%
rmsprop	464	0.001	55.34%
rmsprop	695	0.0001	59.54%
Adam	102	0.001	26.70%
Adam	788	0.0001	61.82%

Tabelle 6: Vergleich zwischen Optimierern

4.3.4 Batch-Normalisierung.

Das Training tiefer neuronaler Netze ist sehr kompliziert und ein Grund dafür ist zum Beispiel die Tatsache, dass die Parameter einer Schicht während des Trainings tiefer neuronaler Netze immer unter der Annahme, dass sich die Parameter anderer Schichten nicht ändern, aktualisiert werden und da alle Schichten während des Updates geändert werden, verfolgt das Optimierungsverfahren ein Minimum, das sich ständig bewegt. Ein anderer Grund dafür ist die ständigen Veränderungen im Laufe des Trainings in die Verteilung des Netzinputs, diese Veränderung wird von [13] als interne kovariate Verschiebung(*Internal Covariate Shift*) genannt und um dieses Problem zu lösen, wird vorgeschlagen, die Netzwerkeingabe zu normalisieren. Aber dieser Ansatz bringt nicht so viel, wenn das NN sehr tief ist, denn nur der Netzinput profitiert von der Normalisierung und die kleinen Veränderungen in versteckte Schichten werden sich immer mehr verstärken, je tiefer man das Netz durchläuft. Mit der Ausbreitung tiefer NNs dehnt die Idee der Datennormalisierung auch auf versteckte Schichten tiefer NNs aus. Bei der BN werden die Eingaben in einem Netzwerk, die entweder auf die Aktivierungen einer vorherigen Schicht oder auf direkte Eingaben angewendet wird, so standardisiert, dass der Mittelwert in der Nähe von null liegt und die Standardabweichung in der Nähe von eins liegt. Die BN wird über Mini-Batches und nicht über den gesamten Trainingssatz durchgeführt, daher enthalten wir nur Näherungen an tatsächliche Werte der Standardabweichung und des Mittelwerts über das Trainingssatzes, aber wir gewinnen an Geschwindigkeit und an Speicherplatzverbrauch.Der Algorithmus 4 gibt die formale Beschreibung des BN an.

Wenn $\gamma = \sqrt{\sigma_\beta^2 + \epsilon}$ und $\beta = \mu_\beta$, bekommen wir die gleiche Verteilung wie vor der Batch-Normalisierung, d.h die Eingabe war also schon normalisiert. Interessanterweise kann das Netz während des Trainings eine bessere Verteilung als die erwünschte finden, denn γ und β sind lernbare Parameter.

Input: Mini-Batch: $B = \{x_{1...m}\}$, Lernbare Parameter β, γ
Output: $y_i = BN_{\beta,\gamma}(x_i)$
1 Mini-Batch Mittelwert : $\mu_\beta = \frac{1}{m}\sum_{i=1}^{m} x_i$;
2 Mini-Batch Standardabweichung :$\sigma_\beta^2 = \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_\beta)^2$
3 Normalisierung: $\widehat{x_i} = \frac{x_i - \mu_\beta}{\sqrt{\sigma_\beta^2 + \epsilon}}$
4 Skalierung und Verschiebung :$y_i = \gamma\widehat{x_i} + \beta \equiv BN_{\gamma,\beta}$

Algorithm 4: Batch-Normalisierung-Algorithmus [13].

Durch die BN kann zum einen eine hohe Lernrate verwendet,was in tiefer NNs ohne BN dazu führen kann, dass die Gradienten explodieren oder verschwinden und in schlechten lokalen Minima stecken bleiben.Die Verwendung einer höhere Lernrate ermöglicht einer schnellere Konvergenz. Zum anderen wird die interne kovariate Verschiebung geringer, was das Training beschleunigt, in einigen Fällen durch Halbierung der Epochen oder besser. Noch dazu wird das Netz durch die BN in gewissem Maße reguliert, daher wird die Verwendung von Dropout bzw. Regulierungstechnik reduziert oder sogar überflüssig und somit eine Verbesserung der Verallgemeinerungsgenauigkeit.

Aber die Verwendung von BN scheint keine Wirkung auf *TemkiNet* zu haben, wenn die Lernrate zu klein ist und die Experimente zeigen, dass die Anwendung der Batch-Normalisierung bei Verwendung eine kleine Lernrate überflüssig ist.

Batch-Normalisierung	Genauigkeit	Lernrate
Ja	55.01%	0.001
$Nein$	28.57%	0.001
Ja	61.82%	0.0001
$Nein$	62.23%	0.0001

Tabelle 7: Einfluss der Batch-Normalisierung auf *TemkiNet*.

4.3.5 Bildgröße.

Die Bilder in einem Datensatz haben in den meisten Fällen nicht die gleiche räumliche Dimension, und leider erfordert das Batch-Training nur gleich große Einträge, so dass alle Bilder vor der Verarbeitung in der Größe angepasst werden müssen, und eine direkte Folge davon ist der Verlust von Informationen.Die Wirkung dieses Informationsverlusts wird in der Tabelle8 gut illustriert.

Aus der Tabelle 8 stellt man fest, dass je größer die Eingabe, desto besser die Leistung des Netzwerkes, desto mehr Parameter bzw. Speicherplatz wird benötigt oder desto länger die Dauer der Inferenz.

Bildgröße	Genauigkeit	#Parameter	Inferenz($\frac{ms}{50Bild}$)	Datensatz
100×100	61.82%	1.418.817	519	food-101-T
150×150	64.87%	2.142.785	717	food-101-T
224×224	67.69%	5.546.659	1000	food-101-T

Tabelle 8: Einfluss der Qualität des Datensatzes

4.3.6 Anzahl der Neuronen pro Schicht:

Wie in 4.2.2.4 erwähnt, alle ConvLs in *TemkiNet* die gleiche Anzahl von Neuronen haben. Die Tabelle 9 oder Abbildung 32 ?? zeigt, wie die Anzahl der Feature-Maps pro Schicht die Netzwerkleistung beeinflusst.Die Abbildung 32 zeigt, dass die *TemkiNet*-Architektur mit weniger Einheiten pro Schicht besser arbeitet und weniger unter Overfitting leidet.Zwar bringt die Erhöhung der Einheiten pro Schicht eine Verbesserung der Netzwerkleistung, aber es lohnt sich nicht, wenn man sich den Speicherbedarf ansieht.

Einheit	Genauigkeit	#Parameter
101	60.52%	1.243.683
202	62.12%	2.725.555
303	61.53%	4.554.261

Tabelle 9: Einfluss der Anzahl von Neuronen pro Schicht.

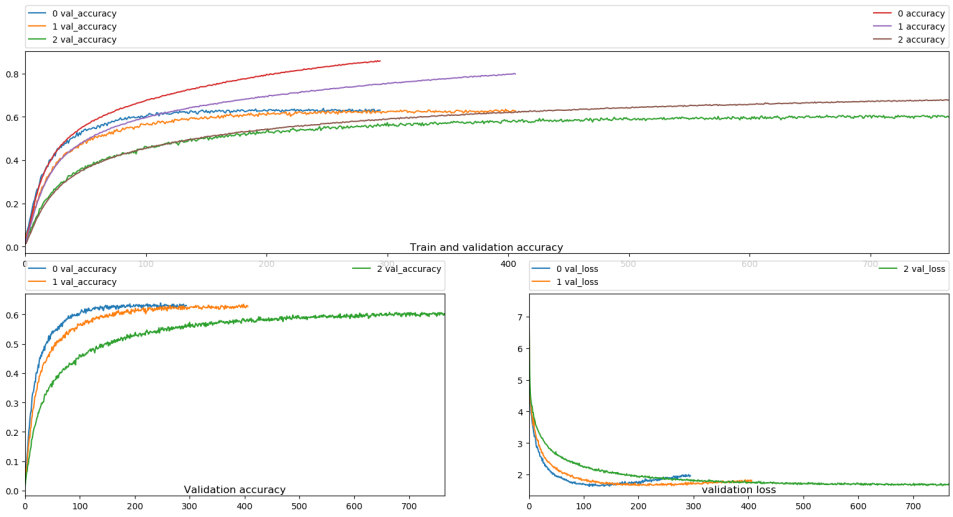

Abbildung 32: Einfluss der Anzahl von Neuronen pro Schicht.

4.3.7 Qualität des Datensatzes

In diesem Teil der Arbeit untersuchen wir, wie die Qualität des Datensatzes die Leistung des Netzwerks beeinflussen kann. Dazu nutzen wir die beiden *Food*-101-Datensätze.Die Abbildung33 zeigt einige Bilder und zugeordnete Labels.Egal wie gut ein CNN trainiert ist, es gibt keine Chance, dass es die gute Antwort gibt, wenn es solchen Input bekommt. Wie in Abbildung 33 und in Tabelle 10 zu sehen ist, ist es notwendig, bei der Aufteilung des Datensatzes eine bessere Bildqualität für den Validierungsdatensatz oder den Testdatensatz auszuwählen.

Abbildung 33: Problem mit Datensätzen.

1. Dropout.
   - 0.1
   - 0.05
2. Lernrate.
   - 0.001

Datensatz	Bildgröße	Genauigkeit	#Parameter
food-101-T	100×100	61.82%	1.418.817
food-101-O	100×100	67.08%	1.418.817
food-101-T	150×150	64.87%	2.142.785
food-101-O	150×150	71.56%	2.142.785
food-101-T	224×224	67.69%	5.546.659
food-101-O	224×224	73.60%	5.546.659

Tabelle 10: Einfluss der Qualität des Datensatzes

- 0.0001
- 0.00005

3. Datensatz.
   - Food-101-O
   - Food-101-T.
   - Food-101-6.
   - Food-101-SVD.

4.4 Einfluss der Lernrate

Wie in 2.2.2.3 gesehen, die Lernrate sagt uns, wie schnell wir ans Ziel kommen. seien η_{opt} und η die optimale bzw. die ausgewählte Lernrate für die Lösung unserer Aufgabe.

Gilt $\eta < \eta_{opt}$, so sind wir sichern, ein lokales oder globales Minimum zu erreichen.Aber die Anzahl der benötigten Iterationen bis zum Minimum steigt offensichtlich an und das Verfahren kann leichter in einem unerwünschten lokalen Minimum stecken bleiben .

$\eta > \eta_{opt}$:Hier wird die Anzahl der Iterationen entweder reduziert oder erhöht.Das Verfahren ist im Allgemein nicht stabil, denn es wird über das Minimum ständig hinausgegangen und es ist nicht mehr sichern, zu einem lokalen oder globalen Minimum zu gelangen. Wenn eine hohe Lernrate angewendet wird, kann man versuchen, das Verhalten des CNN zu kontrollieren, indem man die Lernrate nach einer Reihe von Iterationen reduziert, bei denen sich die Metrik (Netzwerkgenauigkeit oder Netzwerkfehler) nicht mehr verbessert hat ,oder indem man Optimierer(4.3.3) verwendet, die im Laufe des Trainings die Lernrate entsprechend der Eingabe und der aktuellen Lernrate anpassen. Der Grund, warum die Lernrate immer reduziert und nicht erhöht werden muss, sollte daran liegen, dass das CNN irgendwann gut trainiert ist und sollte daher neuen Informationen nicht mehr Gewicht beimessen als dem bereits Gelernten.

- Aus der Abbildung(34) stellt man zuerst fest, dass die Verwendung verschiedener Lernrate zu unterschiedenen Ergebnissen führt und Je höher die Lernrate, desto mehr Schwankungen gibt es.

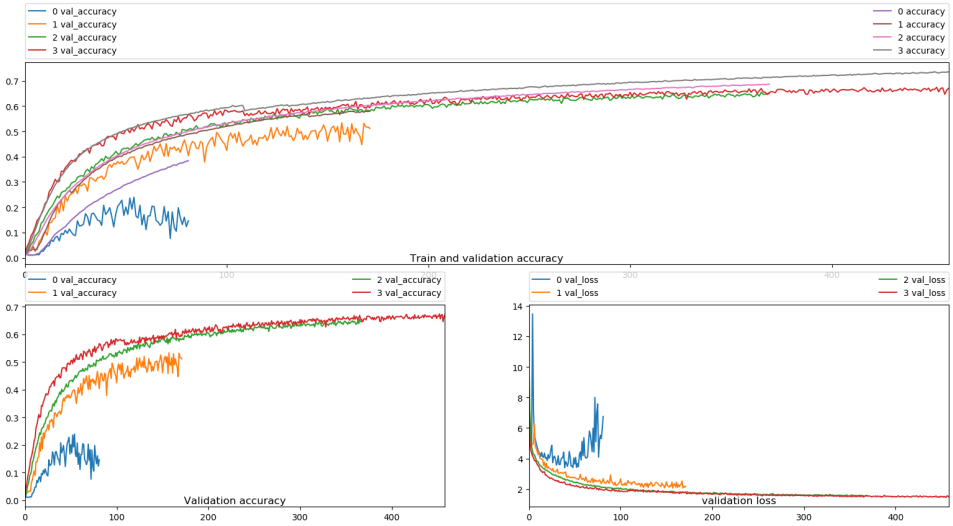

0: 0.001 1: 0.0005 2: 0.00005 3: 0.0001

Abbildung 34: Einfluss der Lernrate auf ein $(224, 224, 3)$Bild.

- Die Reduzierung der Lernrate, wenn sich das Netzwerk nicht mehr verbessert, verbessert die Netzwerkleistung.In der Abbildung gibt es eine jähe Erhöhung der Netzwerkleistung(*orange Kurve*). Das markiert die Änderung der Lernrate von 0.005 auf 0.00001. Um zu erkennen, dass sich das Netzwerk nicht mehr verbessert, werden sogenannte „*Callback* "-Funktionen verwendet, die fordern, dass bestimmte Hyperparameter wie der Faktor, um den die Lernrate reduziert wird($new\_lr = old\_lr * factor$) und die Anzahl der Epochen auch *Patience* genannt, die die überwachte Menge(Z.B. der Validierungsfehler oder Validierungsgenauigkeit) ohne Verbesserung produziert haben. Diese Standard-Callback-Funktionen funktionieren leider nur dann gut, wenn der überwachte Menge (pseudo)-monoton(genau wie die ersten beiden Bilder in der Abbildung 35) ist. Diese Standard-Callback-Funktionen nehmen nicht in Betracht die allgemeine Verhalten des Netzwerks im Zeitintervall *Patience*, sondern vergleichen der erste Eintrag in diesem Zeitintervall mit den anderen Einträgen, was zum Fehler führen kann, wie das letzte Bild in der Abbildung 35 gut zeigt.

  Um dieses Problem zu lösen, haben wir eine neue Methode entwickelt, die uns sagt, ob sich die Netzwerkleistung verändert hat und wie sehr sich das Netzwerk verändert hat. Das Verfahren funktioniert wie folgt:

  – Wir zeichnen eine horizontale Linie, die über den Durchschnittswert im Zeitintervall *Patience* verläuft.Also $y = ax + b, (a = 0, b = Durchschnittswert)$, siehe orange Kurve in der Abbildung 35.

  – Dann versuchen wir alle Werte im Zeitintervall *Patience* durch eine affine

Funktion($y = ax + b$) zu approximieren, indem wir ein NN trainieren.Siehe blaue Kurve in der Abbildung 35.

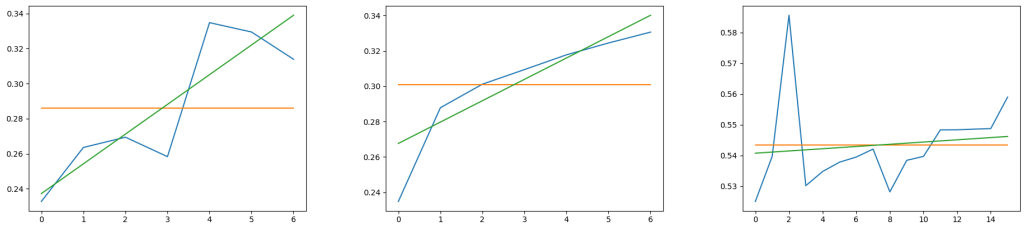

Abbildung 35: Lernraten-Scheduler.

Vergleich zwischen normale LearningRateScheduler und meine

4.5 Problem beim Training von Convolutional neuronale Netzwerke

4.5.1 Overfitting

Wenn ein von der Maschine gelerntes Modell zu gut auf die Trainingsdaten abgestimmt ist und sehr schlechte Vorhersagen über Daten macht, die es noch nie zuvor gesehen hat, so wird gesagt, dass das Modell an einer Überanpassung(Overfitting) leidet, d.h. das Modell ist nicht in der Lage, die relevanten Merkmale aus den Trainingsdaten zu generalisieren, sondern alle Trainingsdaten auswendig zu lernen.Im folgenden werden einige Mittels vorgestellt, um mit der Überanpassung umzugehen.

Dropout Künstliche Neurone sind von biologischen Neuronen inspiriert, aber die Beiden unterscheidet sich sehr voneinander und einer der wichtigen Unterschiede ist, dass biologische Neuronen unvollkommene Maschinen sind, die sehr oft nicht richtig funktioniert und das ist a priori nie den Fall bei künstlichen Neuronen. Wir könnten also glauben, dass KNN die biologische übertreffen könnten.Es sei denn, dass diese Funktionsstörung von biologischen Neuronen nicht eine Schwäche ist, sondern eher eine Stärke ist.Eine der verblüffenden Entdeckungen in Künstliche Intelligenz (KI) Bereich ist, dass es wünschenswert ist, künstliche Neuronen von Zeit zu Zeit zu Fehlfunktionen zu bringen[2]. Jetzt können wir uns fragen, wie Dysfunktion von Neuronen die Performances CNNs verbessern kann.Die zufällige Hinzufügen von Dysfunktionen in einer Schicht der CNN wird *Dropout* benannt und wurde von [4, Geoffrey E. et al] eingeführt.

- Funktionsweise von Dropout.
  Genauer gesagt,Dropout bezeichnet die zeitliche zufällige Ausschaltung von Neuronen(versteckt und sichtbar) in einem NN [5]. Wie die Abbildung 36 zeigt, wenn ein Neuron zufällig aus dem NN entfernt wird, werden auch all seine ein- und ausgehenden Verbindungen entfernt. In einer Dropout-Schicht wird ein Neuron N

unabhängig von anderen Neuronen mit einer Wahrscheinlichkeit p zurückgehalten, d.h N wird mit einer Wahrscheinlichkeit von p nicht am Ergebnis der Schicht teilnehmen. Während der Testphase werden alle Verbindungen zurückgesetzt, die während des Trainings gelöscht wurden und die ausgehenden Verbindungen gelöschter Neurone mit p multipliziert.

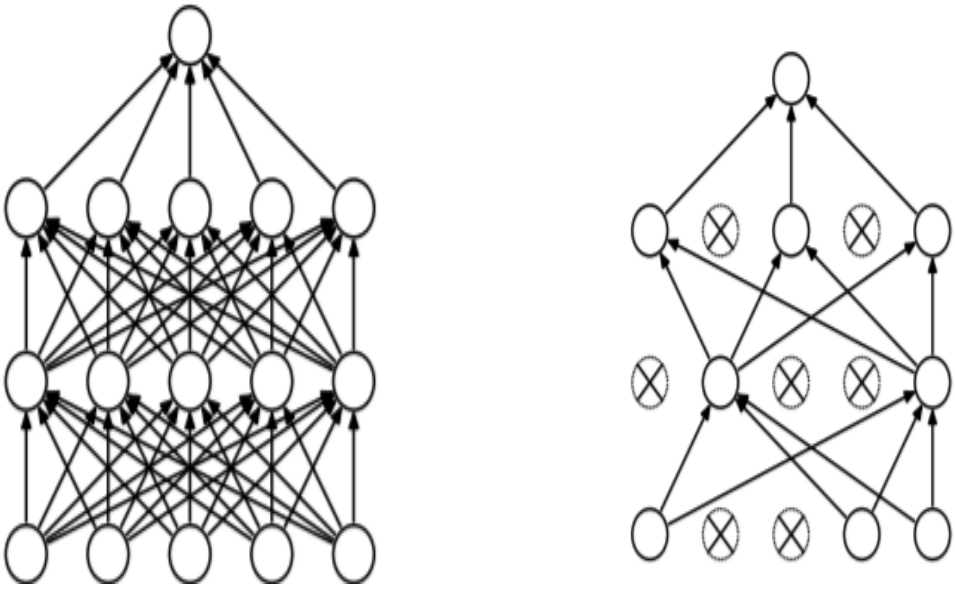

(a) Standard neuronale Netze (b) Netze nach Dropout

Abbildung 36: Neuronales Netz mit Dropout ausgestattet [5].

- Verhinderung der Koadaptationen zwischen Neuronen.
  Während des Trainings können mehrere Neurone zur Minimierung der Fehlerfunktion so gut zusammenarbeiten, dass die Erkennung bestimmter Merkmale ohne diese Zusammenarbeit nicht mehr möglich ist, aber solche komplexe Koadaptationen können zu einer Überanpassung führen, denn diese komplexe Koadaptationen existieren nicht immer in Testdaten. Da die am Training teilnehmenden Neuronen nach dem Zufallsprinzip nach jeder Epoche ausgewählt werden, haben wir für jedes Training ein neues Modell, was die Neuronen zur Zusammenarbeit zwingt, ohne jedoch voneinander abhängig zu sein, anders gesagt, wird jedes Neuron unabhängig von anderen Neuronen die Muster korrekt lernen können.

- Automatische Erhöhung von Training Daten und Regelung .
  Noch dazu führt die Ausschaltung von Neuronen, wie es in Abbildung 37 angezeigt ist, zu einer automatische Erzeugung neuer Trainingsdaten. Die verwendeten Daten in ausgedünnten Modellen sind also nur eine Abstraktion von echten Daten bzw. Rauschdaten und da wir für ein Netz mit n versteckten Einheiten, von denen jede fallen gelassen werden kann, 2^n mögliche Modelle haben, haben wir 2^n mögliche Abstraktion von unseren Daten und das sollte einer der Gründe sein, warum

Dropout effektiver als andere rechnerisch kostengünstige Regler ist [5] und warum die Trainingszeit von NNs mit Dropout mindestens verdoppelt wird.

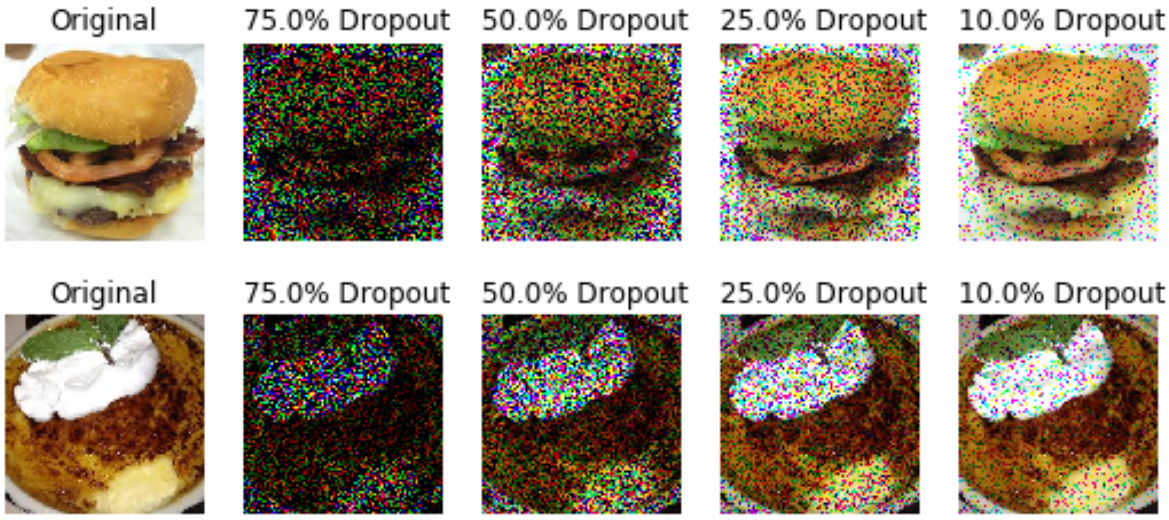

Abbildung 37: Erhöhung des Trainingsdaten durch Dropout

Da heutige CNNs Million von Neurons haben, wäre es unmöglich alle mögliche ausgedünnte Netzwerke zu trainieren, deshalb ist das Modell, das am Ende des Trainings erhalten wird, nur eine durchschnittliche Approximation aller mögliche Modelle, was schon gut, denn es gibt schlechte und gute Modelle.

4.6 Extreme Version von TemkiNet.

4.7 Erhöhung der Inferenzzeit und Verringerung des Speicherbedarfs

4.7.1 Quantisierung

4.7.2 Pruning

5 Diskussion

6 Schluss

Literatur

[1] Michael H. Zhu, Suyog Gupta. To prune, or not to prune: exploring the efficacy of pruning for model compression

[2] P. Kerlirzin, and F. Vallet: Robustness in Multilayer Perceptrons

Block	Schrittgröße	Outputgröße
conv_Block	2×2	$(100, 100, 101)$
Max-Pool-Block	2×2	$(50, 50, 101)$
Depthwise_Block 1	1×1	$(50, 50, 101)$
Max-Pool-Block	2×2	$(25, 25, 101)$
2×Depthwise_Block 1	1×1	$(25, 25, 101)$
Max-Pool-Block	2×2	$(12, 12, 101)$
3×Depthwise_Block 1	1×1	$(12, 12, 101)$
Max-Pool-Block	2×2	$(6, 6, 101)$
4×Depthwise_Block 1	1×1	$(6, 6, 101)$
Max-Pool-Block	2×2	$(3, 3, 101)$
2×Depthwise_Block 1	1×1	$(3, 3, 101)$
GlobalAveragePooling2D	/	101
Flatten	/	101

Tabelle 11: *TemkiNet* Extratorblock von einigen Extremversion mit 101 Feature-Maps pro ConvL

Block	Schrittgröße	Outputgröße
Dense_Block	/	505
Dense_Block	/	505
FC		101

Tabelle 12: *TemkiNet* 1 Klassifikatorblock

Block	Schrittgröße	Outputgröße
Dense_Block	/	404
Dense_Block	/	404
FC		101

Tabelle 13: *TemkiNet* 2 Klassifikatorblock

Block	Schrittgröße	Outputgröße
Dense_Block	/	303
Dense_Block	/	303
Dense_Block	/	303
FC		101

Tabelle 14: *TemkiNet* 3 Klassifikatorblock

Block	Schrittgröße	Outputgröße
conv_Block	2×2	$(100, 100, 101)$
Depthwise_Block	2×2	$(50, 50, 101)$
Depthwise_Block	1×1	$(50, 50, 101)$
Depthwise_Block	2×2	$(25, 25, 101)$
2×Depthwise_Block	1×1	$(25, 25, 101)$
Depthwise_Block	2×2	$(12, 12, 101)$
3×Depthwise_Block	1×1	$(12, 12, 101)$
Depthwise_Block	2×2	$(6, 6, 101)$
4×Depthwise_Block	1×1	$(6, 6, 101)$
Depthwise_Block	2×2	$(3, 3, 101)$
2×Depthwise_Block	1×1	$(3, 3, 101)$
GlobalAveragePooling2D	/	101
Flatten	/	101
Dense_Block	/	202
Dense_Block	/	202
Dense_Block	/	202
FC		101

Tabelle 15: TemkiNet 4 Architektur mit 101 Feature-Maps pro ConvL

Modell	Bildgröße	Genauigkeit	#Parameter	Inferenz
TemkiNet	100×100	61.82%	1.418.817	
TemkiNet_1	100×100	60.78%	781.437	
TemkiNet_2	100×100	??%	668.216	
TemkiNet_3	100×100	59.66%	668.721	
TemkiNet_4	100×100	58.47%	668.721	
TemkiNet	150×150	64.87%	2.142.785	
TemkiNet_1	150×150	64.88%	781.437	

Tabelle 16: Variante von *TemkiNet*.

[3] Md. Zahangir Alom,Tarek M. Taha, Christopher Yakopcic,Stefan Westberg,Mahmudul Hasan,Brian C. Van Esesn , Abdul A. S. Awwal und Vijayan K. Asari The History Began from AlexNet: A Comprehensive Survey on Deep Learning Approaches

[4] Geoffrey E. Hinton and Nitish Srivastava and Alex Krizhevsky and Ilya Sutskever and Ruslan R. Salakhutdinov: Improving neural networks by preventing co-adaptation of feature detectors

[5] Srivastava, Hinton, Krizhevsky, Sutskever and Salakhutdinov: Dropout: A Simple Way to Prevent Neural Networks from Overfitting

[6] Ian Goodfellow, Yoshua Bengio, Aaron Courville: Adaptive Computation and Machine Learning series Page 342

[7] Song Han, Huizi Mao, William J. Dally Deep Compression: Compressing Deep Neural Networks with Pruning, Trained Quantization and Huffman Coding

[8] Hao Li, Asim Kadav, Igor Durdanovic, Hanan Samet, Hans Peter Graf Pruning Filters for Efficient ConvNets

[9] Franco Manessi, Alessandro Rozza, Simone Bianco, Paolo Napoletano, Raimondo Schettini Automated Pruning for Deep Neural Network Compression

[10] Emily Denton,Wojciech Zaremba,Joan Bruna,Yann LeCun and Rob Fergus Exploiting Linear Structure Within Convolutional Networks for Efficient Evaluation

[11] Pavel Golik , Patrick Doetsch, Hermann Ney Cross-Entropy vs. Squared Error Training:a Theoretical and Experimental Comparison

[12] Neuronale Netze:Eine Einführung

[13] Sergey Ioffe, Christian Szegedy Batch Normalization: Accelerating Deep Network Training b y Reducing Internal Covariate Shift

[14] Wikipedia: Learning Rate

[15] John Duchi,Elad Hazan, Yoram Singer: Adaptive Subgradient Methods for Online Learning and Stochastic Optimization

[16] Diederik P. Kingma, Jimmy Ba: Adam: A Method for Stochastic Optimization

[17] Compressing Models:Quantization

[18] Yoni Choukroun, Eli Kravchik, Fan Yang, Pavel Kisilev: Low-bit Quantization of Neural Networks for Efficient Inference

[19] wikipedia: Artificial neuron

[20] Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton ImageNet Classification with Deep Convolutional Neural Networks

[21] Forrest N. Iandola, Song Han, Matthew W. Moskewicz, Khalid Ashraf, William J. Dally, Kurt Keutzer: SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5MB model size

[22] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun: Deep Residual Learning for Image Recognition

[23] François Chollet Xception: Deep Learning with Depthwise Separable Convolutions

[24] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jonathon Shlens, Zbigniew Wojna Rethinking the Inception Architecture for Computer Vision

[25] Andrew G. Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, Hartwig Adam MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications

[26] Bossard, Lukas and Guillaumin, Matthieu and Van Gool, Luc:Food-101 – Mining Discriminative Components with Random Forests